

최종 프로젝트 : 개인화 맞춤 선물 추천

Recsys-04

파이팅해야조

GiftHub 프로젝트

김세훈, 김시윤, 문찬우, 배건우, 이승준

INDEX



1. Intro

프로젝트 기획

2. model/ research

2.1 데이터셋

2.2 모델

3. product serving

3.1 서비스 아키텍처

3.2 구현

3.3 데모

4. result/ conclusion

4.1 시연 영상

4.2 후속 개발 및 연구

4.3 결과 및 고찰

5. Appendix

5.1 팀원 구성

5.2 협업 전략

5.3 프로젝트 타임라인

5.4 Refernce

1. Intro

프로젝트 기획

주제 선정 배경



다른 사람들은 무엇을 선물 했을까?

취향에 맞는 선물은 뭘까?



특별한 날 더 특별해지고 싶은 당신을 위한 추천 시스템

주제 선정 배경

선물하기 서비스 시장 상황

온라인 선물하기 시스템의 이용자 수 증가

- ▶ 온라인 선물하기 서비스의 시장 규모는 2016년 부터 **6년간 5배 증가**
- ▶ 설문 조사 응답자 87.8% 모바일 선물하기 일상화¹⁾

온라인 선물하기 시스템의 긍정적인 효과²⁾

- ▶ 간단한 사례 및 선물하기가 좋아졌다 93.7%
- ▶ 선물 고르는 과정의 **시간과 노력을 줄여준다 79.4%**

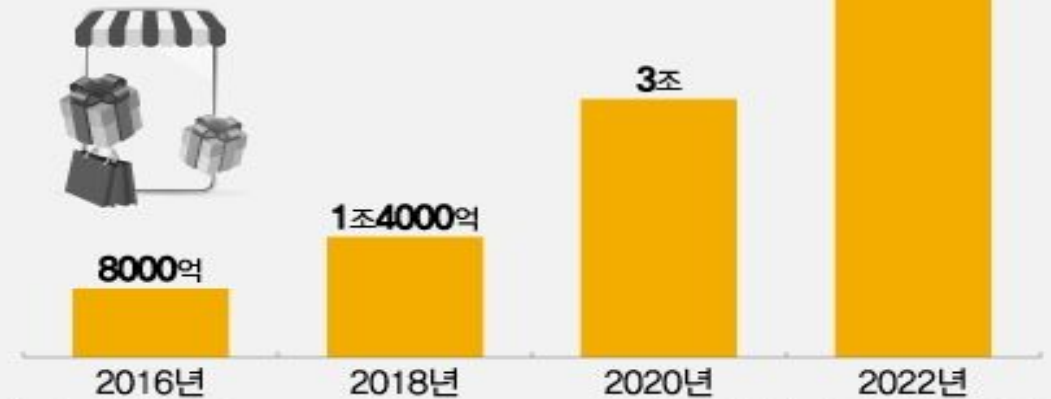
온라인 선물하기 시스템에 대한 거부감²⁾

- ▶ '정이 없다'는 응답이 24.3%
- ▶ '성의 없어 보인다'가 16.5%

조선경제 > 테크

‘카톡 선물하기’ 늘자… 카카오 작년 매출 8조원 돌파

국내 온라인 선물하기 서비스 시장 규모 (단위: 원)



*자료 : 업계추산
그래픽: 조수아 디자인기자

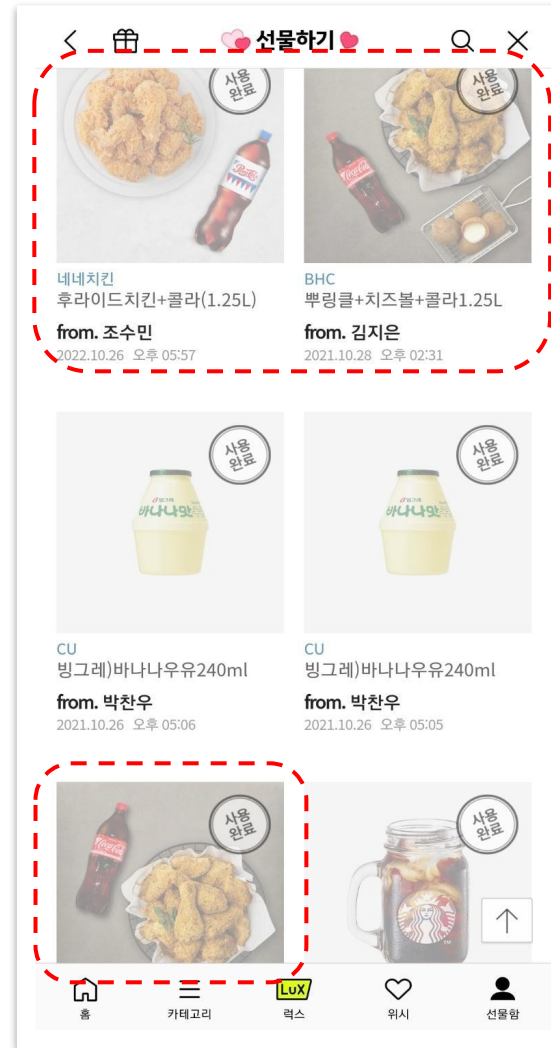
1) 아시아 경제, "10명중 9명, 모바일 선물하기" e커머스, 점유율 확대 총력, <https://www.asiae.co.kr/article/2023071116442044921>

2) 데이터 슝, '모바일로 선물하기'에 익숙하다 87% 넘어, <https://www.datasom.co.kr/news/articleView.html?idxno=127405>

주제 선정 배경

지금까지의 온라인 선물의 단점은 뭘까?

- ▶ 받는 것만 받는다 (ex. 치킨 기프티콘을 매우 많이 받아왔다)
- ▶ 선물하는 상황을 딱히 고려하지 않고 많은 사람들이 산 것을 선물했다.
- ▶ 선물 받는 사람이 아닌, 상품에 초점이 맞추어질 가능성이 크다.



요즘 뜨는 선물이예요



스타벅스
"생일 축하해요" 카페 아메리카
노 T 2잔 + 바스크 치즈 케이크...
22,800원
1,372

스타벅스
"고마운 분께 드려요" 카페 아메
리카노 T + 카페 라떼 T + 바스...
17,400원
1,444

내 또래 남성들은
지금 이런 선물을 구매하고 있어요.

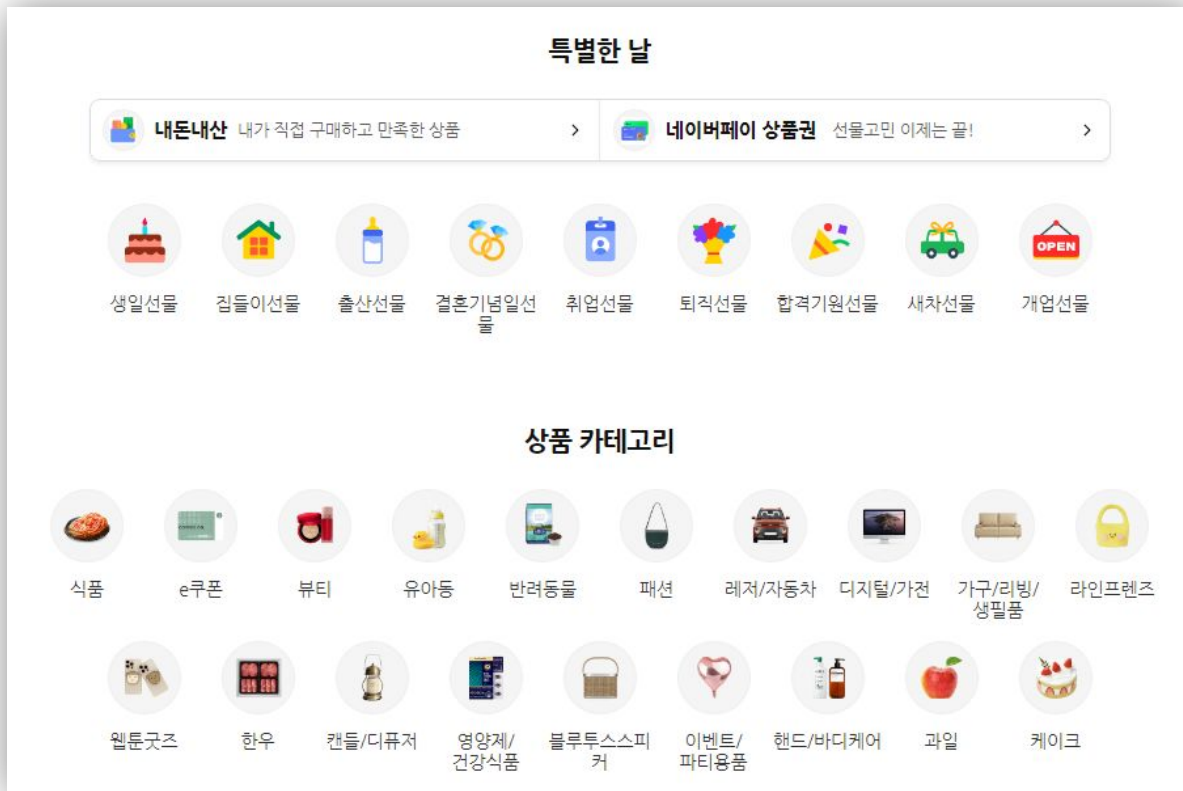


스타벅스 상품권
e카드 2만원 교환권
20,000원
2만+

컴포즈커피
1만원권
10,000원
8,350

주제 선정 배경

내가 “주고 싶은 선물”과 상대가 “받고 싶은 선물”은 다르다.



#추천 시스템의 현재 활용 방법

- 유저의 구매 내역을 기반으로 한 추천 제공

#기존 선물 추천 시스템

- Contents Based : 선물 받는 상황을 고려하여 선물을 추천.
(예시: 생일, 기념일 등 특별한 날에 맞는 선물 제안.)
- 인기도 기반 추천

새로운 선물 추천 시스템의 제안

- 선물하는 사람의 관점에서 상대방의 구매 내역 예측
- 데이터 분석을 통한 개선된 선물 추천 방법

2. Model/ Research

2.1 데이터셋

2.2 모델

2.1 데이터셋



1. 네이버 선물샵

추천하고자 하는 선물샵 크롤링
데이터셋



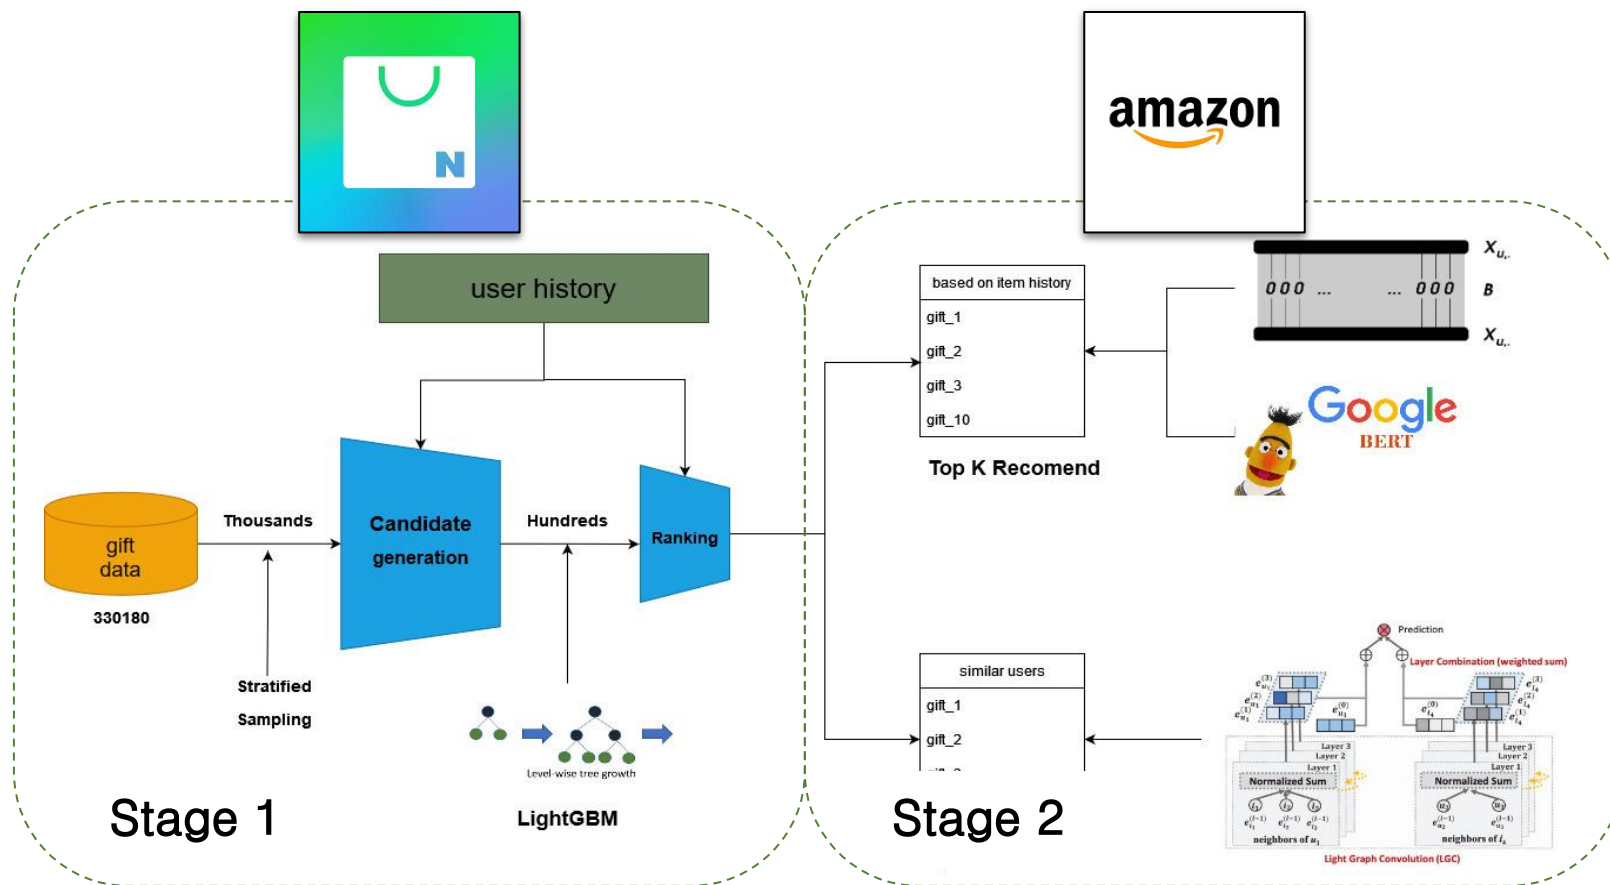
2. 아마존 데이터

유저의 상호작용 데이터를
활용하기 위한 데이터셋

데이터 구성이 2가지인 이유

데이터 종류 \ 아이템별 태그	나이	성별	원화 기준 가격대	선물하는 상황	user interaction
네이버 선물샵	△	△	0	0	X
아마존	X	X	X	X	0

데이터 구성이 2가지인 이유



①'선물 후보군 생성' → ②'맞춤형 개인 추천' : 2단계 추천

데이터 구성

데이터 수집 1.네이버 쇼핑 선물샵 크롤링 데이터



총 74개의 소분류 카테고리

❖ 총 9개 대분류 카테고리 → '선물하는 상황'

데이터 구성

데이터 수집 1.네이버 쇼핑 선물샵 크롤링 데이터

❖ 총 330180개의 데이터 Item unique 131075개



파리바게뜨 >
마이넘버원 케이크
33,000원
★ 4.8 · 리뷰 427

ABC product_id	8044395966
ABC product_name	마이넘버원 케이크
ABC brand	파리바게뜨
ABC category_1	생일선물
ABC category_2	10대 여성
ABC category_3	e쿠폰
123 rating	4.8
123 num_review	393
123 price	33,000
ABC image_url	https://shop-phinf.pstatic.net/2023
ABC product_url	https://shopping.naver.com/gift/pi

컬럼명	Data Type
ABC product_id	varchar(50)
ABC product_name	varchar(128)
ABC brand	varchar(50)
ABC category_1	varchar(50)
ABC category_2	varchar(50)
ABC category_3	varchar(50)
123 rating	double
123 num_review	int(11)
123 price	int(11)
ABC image_url	varchar(500)
ABC product_url	varchar(500)

1개의 product_id에 여러개의 category2, category3가 존재 할 수 있음
(예시 : 마이넘버원 케이크의 category2의 경우 10대 여성, 2030대 여성, 2030대 남성)

이미지 출처 :
<https://brand.naver.com/parisbaguette/products/8044395966>

데이터 구성

데이터 수집 2. Amazon Review Data (2018)

- 1996.05 ~ 2018.10까지 데이터
- 다양한 카테고리 데이터 중 패션 데이터에 한정하여 수집
- **userid, itemid, rating**에 해당하는 user rating 데이터와 image url 활용을 위한 item meta data를 수집
- item unique : 186,189
- user unique : 749,233

Amazon Review Data (2018)

Jianmo Ni, UCSD

Please see the [2023 version of this dataset](#)

This (older) version is mainly here for the sake of reproducing past results

Description

This Dataset is an updated version of the [Amazon review dataset](#) released in 2014. As in the previous version, this dataset includes reviews (ratings, text, helpfulness votes), product metadata (descriptions, category information, price, brand, and image features), and links (also viewed/also bought graphs). In addition, this version provides the following features:

- More reviews:
 - The total number of reviews is 233.1 million (142.8 million in 2014).
- Newer reviews:
 - Current data includes reviews in the range May 1996 - Oct 2018.
- Metadata:
 - We have added transaction metadata for each review shown on the review page. Such information includes:
 - Product information, e.g. color (white or black), size (large or small), package type (hardcover or electronics), etc.
 - Product images that are taken after the user received the product.
 - Added more detailed metadata of the product landing page. Such detailed information includes:
 - Bullet-point descriptions under product title

데이터 전처리



1. Product_id에 대해 카테고리 별 선택 여부를 Entropy로 계산하여 **개성 (personality)** 정의
2. 가격을 기준으로 std 약 3sigma(99%)에 해당하는 **가격 상한선 제한** 후 필터링 & 리뷰 수 **quantile 0.5 이상인 데이터로 필터링**(330,180 → 112,186)
3. 추가적으로 **충화 표집**을 이용한 샘플링 진행(112,186 → 30,000)
4. **Product id 빈도 3 이상**의 카테고리에 속해 있는 상품으로 필터링 → total : 7,869, product_id : 2256



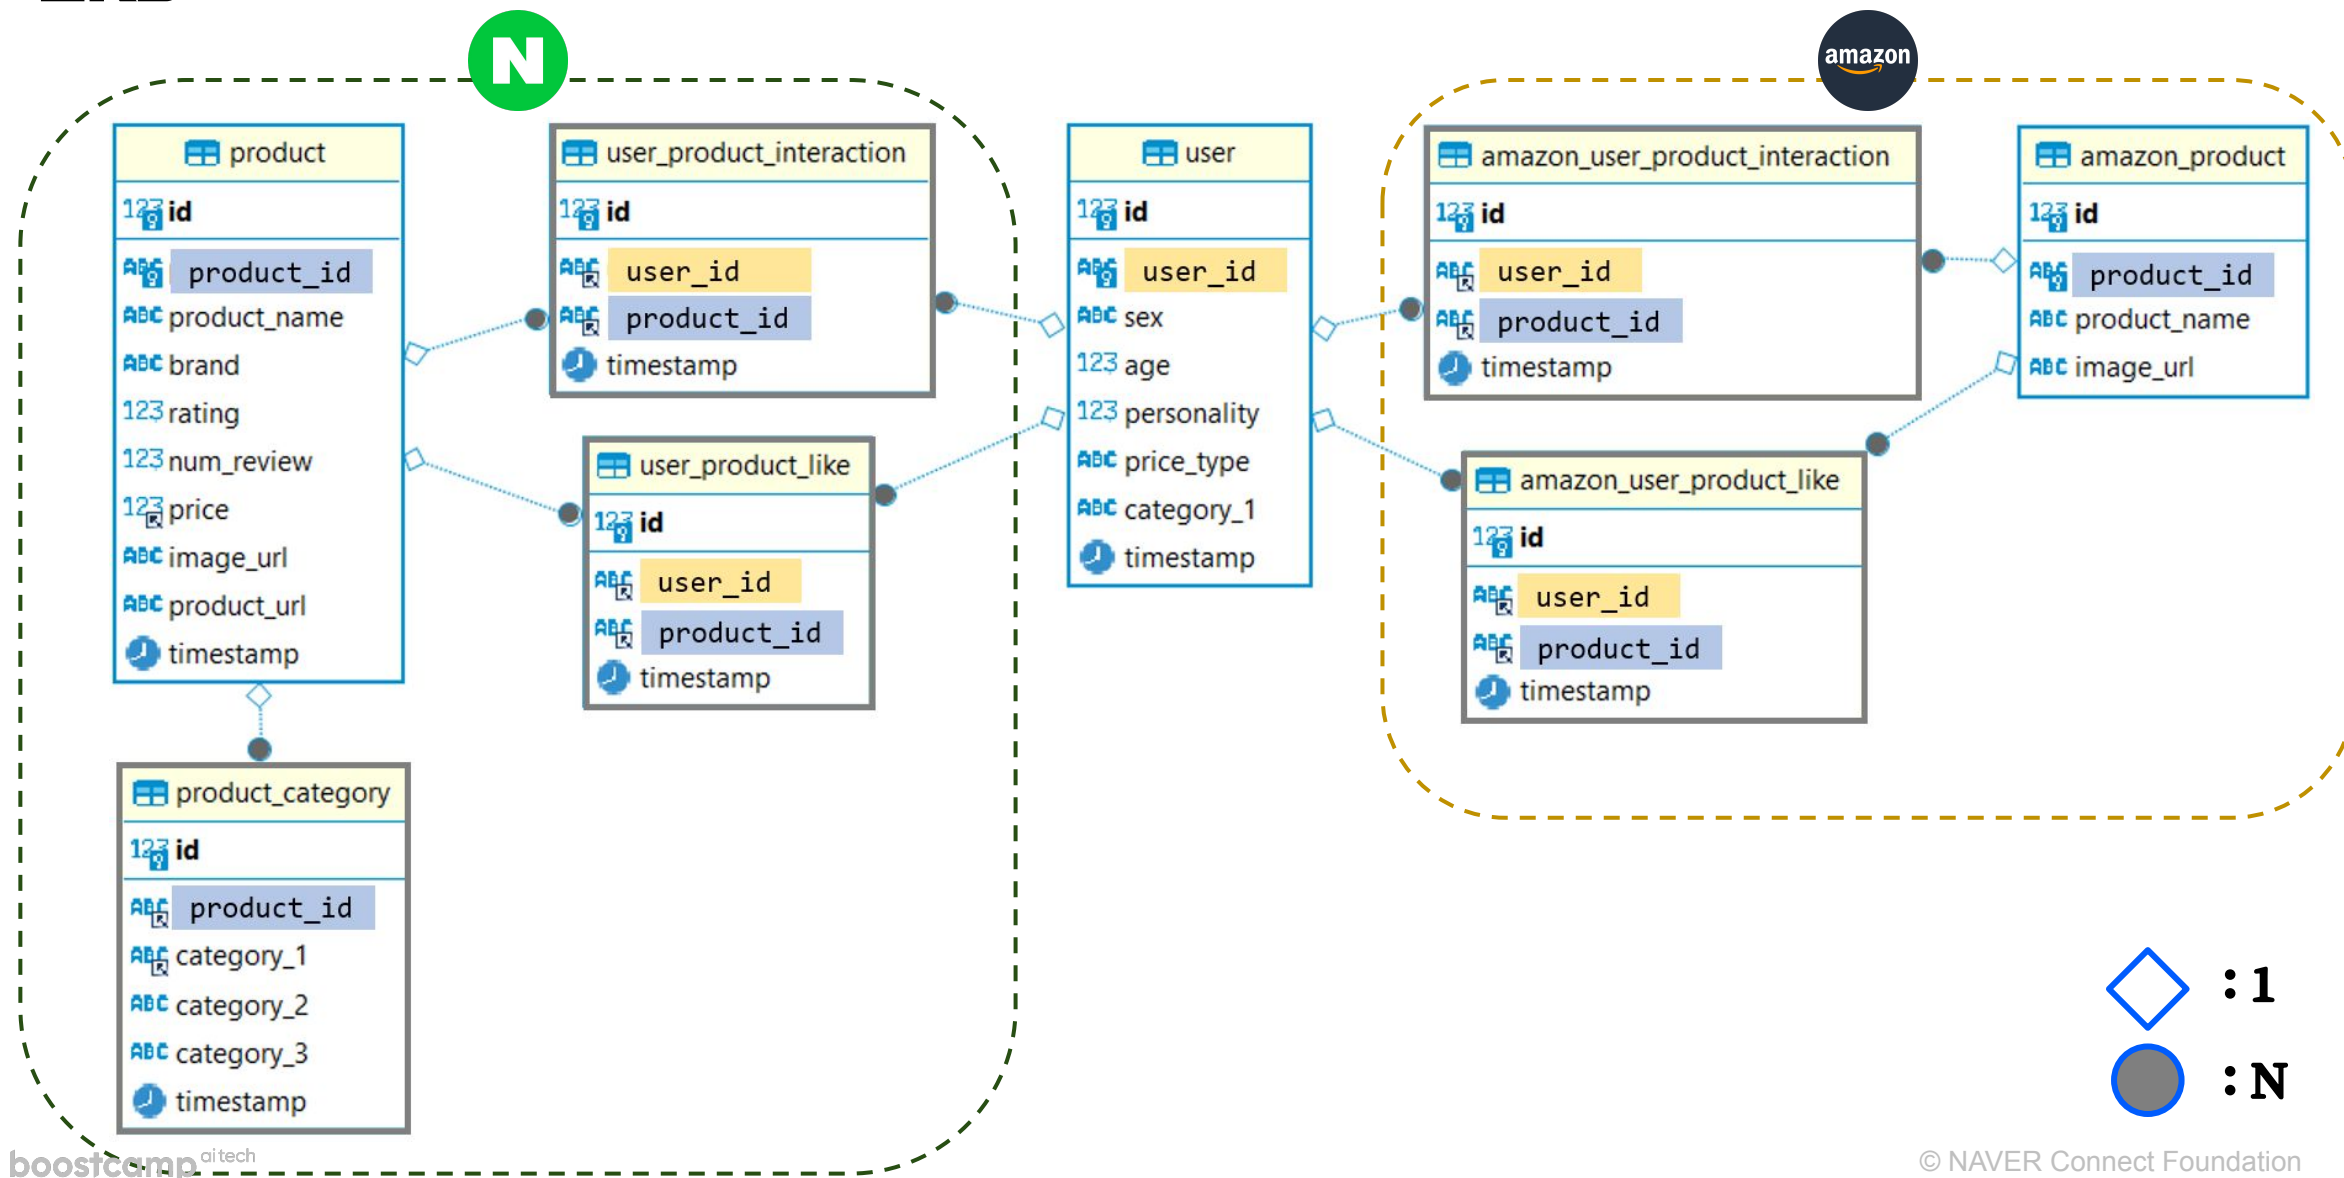
1. 클라이언트에게 보여질 상품 이미지 추출을 위해 상품 Image URL이 존재하는 Row 필터링
2. 상품 이미지 필터링 과정에서 사라진 아이템 때문에 유저 History도 같이 없어짐
→ 상품 이미지 필터링 후 **Rating(상호작용) 빈도가 4 이상인 유저들로 필터링**
3. Rating 3점 이상 Row를 필터링 후 **1(클릭여부)**로 변경

데이터 전처리

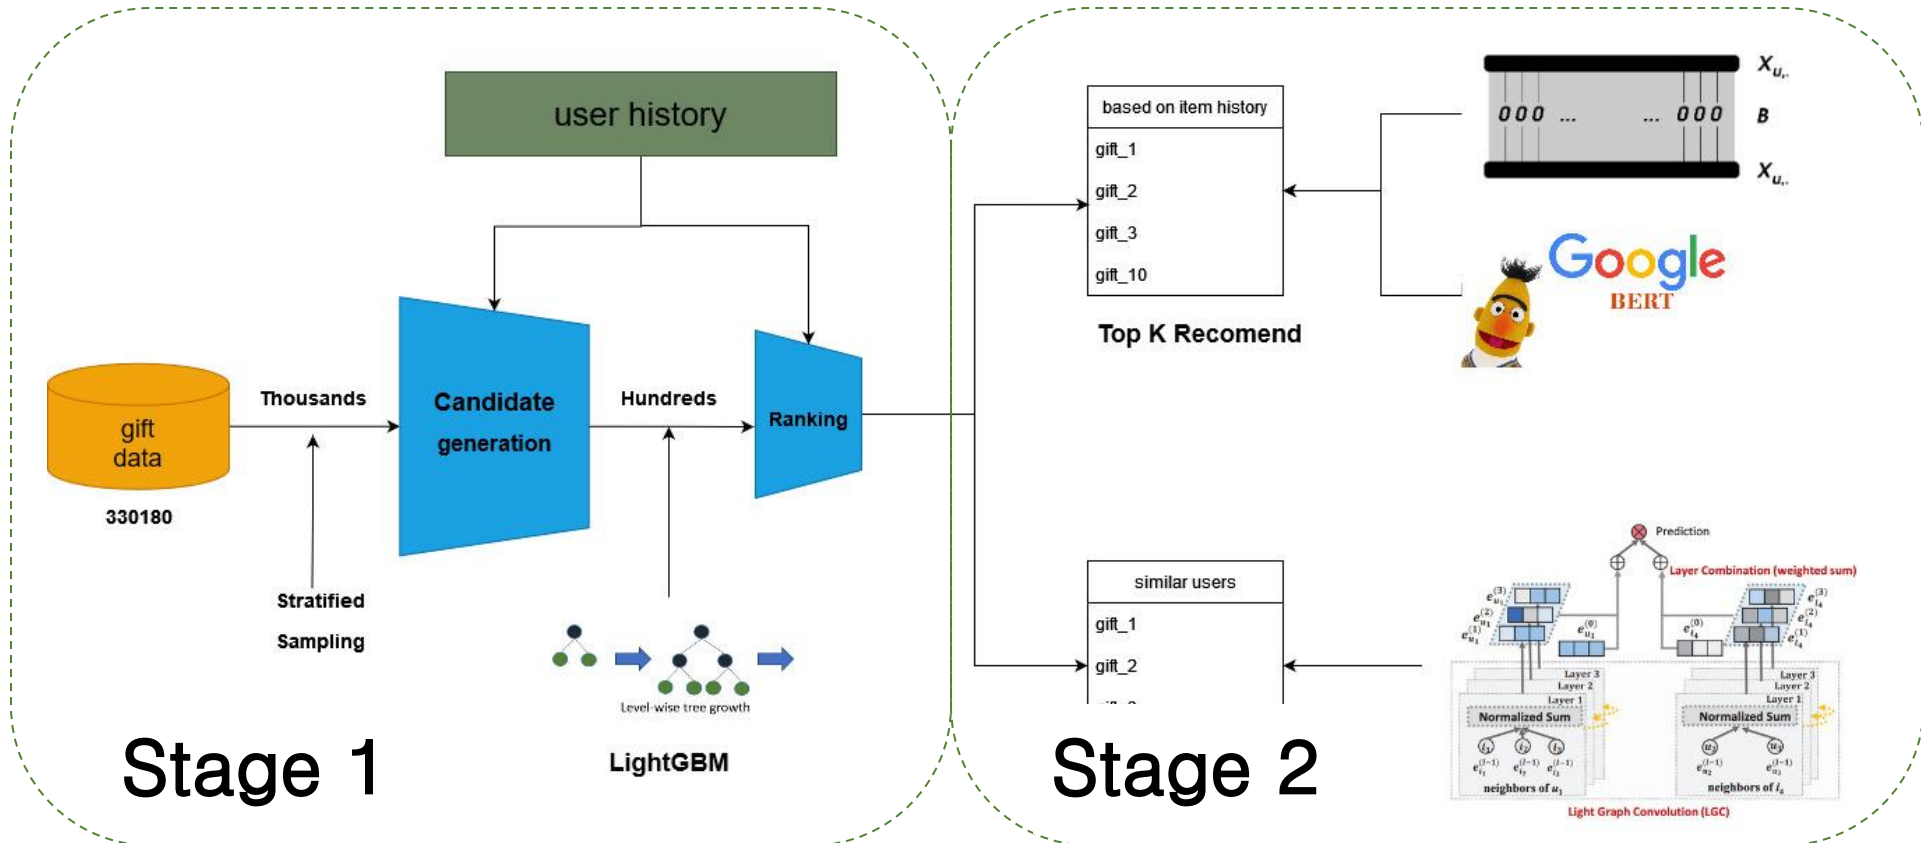
학습에 사용된 최종 데이터 shape

	row	column	product id unique	user id unique	user interaction	sparsity
네이버 선물샵	7869	14	2256	X	X	X
아마존	X	X	6484	2195	12690	0.9991

ERD



2.2 모델링



①'선물 후보군 생성' → ②'맞춤형 개인 추천' : **2단계 추천**

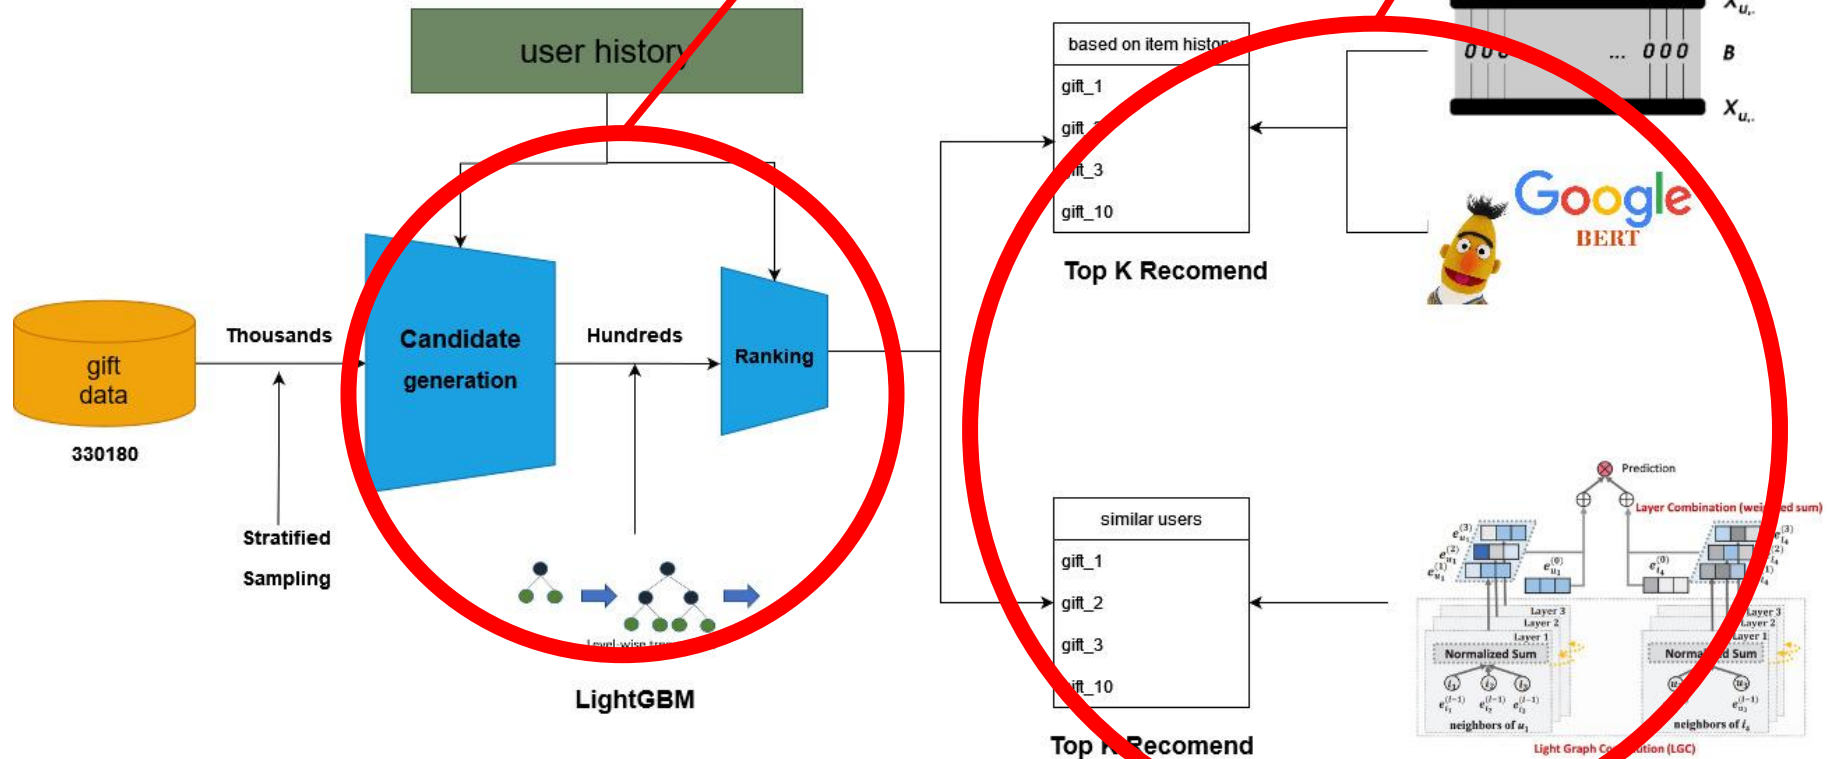
2.2 모델링

모델을 왜 2 Stage로 구성했나?

아이템 메타데이터
[선물하는 상황, 나이, 성별, 가격대]

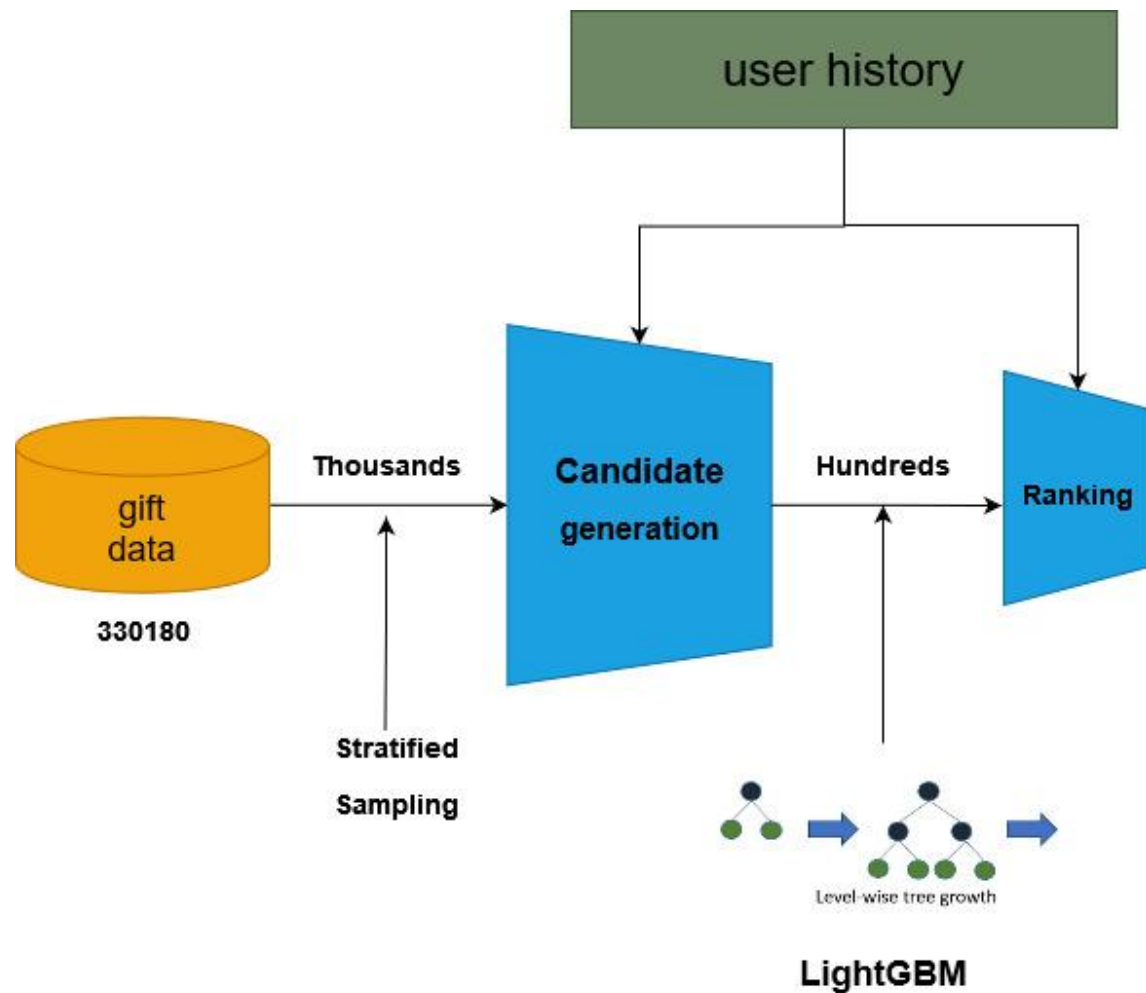
아주 간단한 수준의 개인화

CF를 통한 최종 예측




2.2 모델링

Stage 1



2.2 모델링

Stage 1



Stratified Sampling


1. 카테고리 중분류 상의 아이템들에 대해 **Price**의 하위 0.3 제거 및 상위 0.99(3σ)를 이상치로 판단하고 제거 + 리뷰수가 낮은(백분위 0.5이하) 아이템 제거 (330,000 -> 115,086)
2. 각 카테고리 대분류 및 중분류에 대한 비율 계산
3. 각 분류에 대한 비율을 고려하여 N=30000인 **Sampling(층화표집)** 실행
4. 최종적으로 **Product_ID**에 대한 빈도가 3 이상인 것 반환(30000 -> 7,869)

2.2 모델링

Stage 1


LightGBM

- ❑ 유저의 Input 카테고리/가격대/개성/리뷰 → Top K 아이템 리스트 선정
- ❑ 코사인 유사도를 바탕으로 k개의 선물 아이템 후보군 선정
- ❑ 인기도 기반 후보군으로 카테고리의 다양화 전략 사용



2.2 모델링

Stage 2



1. 아이템 기반 협업 필터링

과거 상호작용을 바탕으로 **아이템간의 유사도** 계산
유저의 **구매패턴**에 인거하여 높은 유사도를 가진 아이템 반환

2. 유저기반 협업 필터링

개인화 추천
사용자 간의 유사도 계산
유사도가 높은 기존의 유저가 선택한 아이템 반환

2.2 모델링

아마존데이터에서 Rating을 Binary로 재정의한 이유

Task 정의

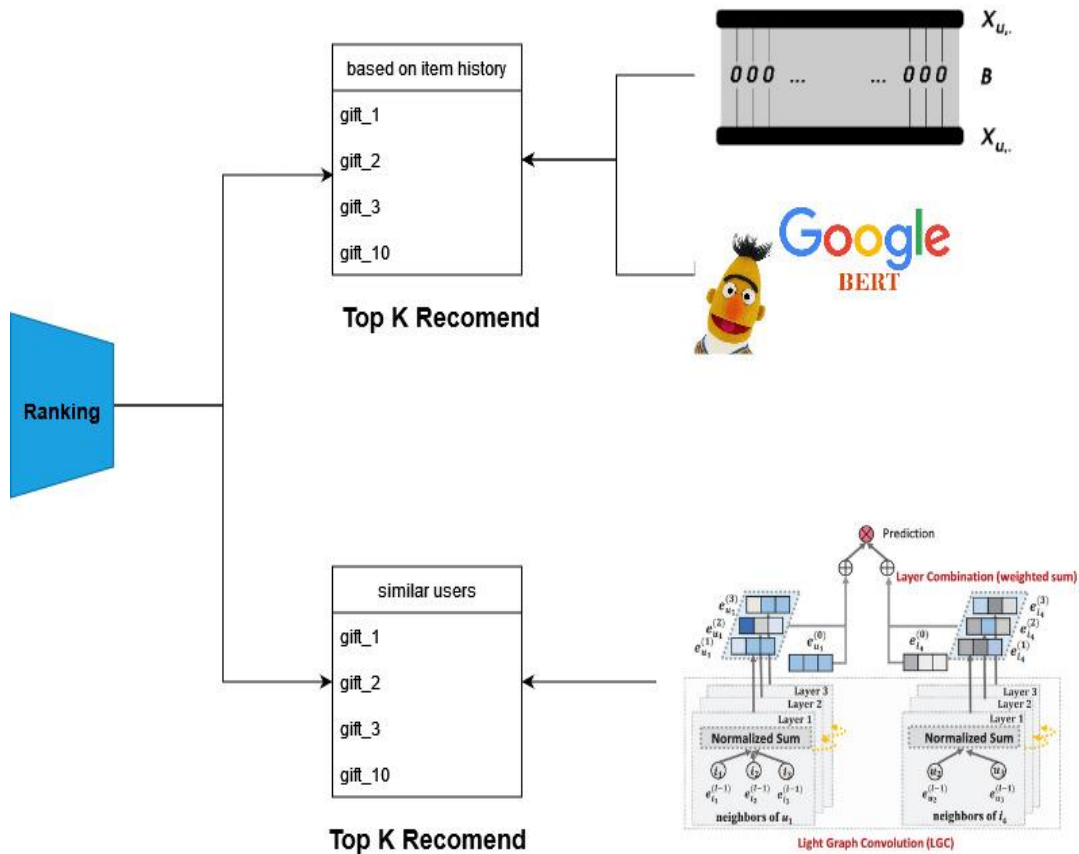
유저가 선물할 만한 상품을 고른다.

Ground-Truth 정의

유저가 고를만한 상품의 interaction을 예측한다.

2.2 모델링

Stage 2



1. 아이템 기반 협업 필터링

과거 상호작용을 바탕으로 **아이템간의 유사도** 계산
유저의 **구매패턴**에 인거하여 높은 유사도를 가진 아이템 반환

2. 유저기반 협업 필터링

개인화 추천
사용자 간의 유사도 계산
유사도가 높은 기존의 유저가 선택한 아이템 반환

2.2 모델링

Recall@k

- 유저가 관심있는 전체 아이템 가운데 **우리가 추천한 아이템**의 비율

$$Recall = \frac{TP}{TP + FN}$$

Precision@k

- 추천한 k개의 아이템 가운데 **실제 유저가 관심있는 아이템**의 비율

$$Precision = \frac{TP}{TP + FP}$$

F1

- Recall과 Precision의 조화평균
- 각 Metric의 Bias를 줄이기 위해 사용

$$F1\ score = 2 * \frac{Precision * Recall}{Precision + Recall}$$

		실제 정답	
		True	False
분류 결과	True	True Positive	False Positive
	False	False Negative	True Negative

2.2 모델링

Cumulative Gain(CG)

- 사용자의 추천된 아이템에 대한 선호도

$$CG_K = \sum_{i=1}^K rel_i$$

Discounted CG(DCG)

- 특정 K개에 대한 선호도

$$DCG_K = \sum_{i=1}^K \frac{rel_i}{\log_2(i + 1)}$$

Ideal DCG(IDC)

- DCG에서 순서를 고려한 선호도

$$IDCG_K = \sum_{i=1}^K \frac{rel_i^{OPT}}{\log_2(i + 1)}$$

Normalized(NDCG)

- Normalized된 DCG 지표

$$NDCG_K = \frac{DCG}{IDCG}$$

2.2 모델링

Cosine Similarity(FAISS)

- 유저 벡터간의 코사인 각도
- 두 유저 벡터의 방향성의 유사도 확인

$$similarity = \cos(\Theta) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i \times B_i}{\sqrt{\sum_{i=1}^n (A_i)^2} \times \sqrt{\sum_{i=1}^n (B_i)^2}}$$

Diversity - ILD(Intra-List Distance)(Kaminskas, M., & Bridge, D. (2016))

- RL(추천 리스트)안의 모든 아이템의 pair의 임베딩에 대한 평균 유클리드 거리
- 유사한 유저가 선택한 아이템들의 다양성

$$ILD = \frac{\sum_{(i,j) \in RL} d_{ij}}{|RL| \times (|RL| - 1)};$$

Trade-Off(Raza, S., Bashir, S. R., & Naseem, U. (2022))

- Accuracy와 Diversity에 대한 조화평균
- 아이템의 다양성과 정확도 간의 균형을 유지하는 것이 중요하다고 판단
 - Accuracy는 F1(Recall@10, Precision@10) 사용
 - Diversity는 ILD 사용
 - 참고논문에서는 MIND, NYTimes 기준 각각 68.91%, 69.18%

$$tradeoff = 2 * \frac{(accuracy * diversity)}{(accuracy + diversity)}$$

2.2 모델링

Item-Based

metric/model	Recall@10	Precision@10	NDCG@10	F1
Bert4REC	0.1753	0.0170	0.1627	0.0310
EASE	0.1900	0.0193	0.1742	0.0351
Random Sampling	0.0016	0.0010	0.0130	0.0013
Popularity@10	0.1708	0.1285	0.1501	0.1467

User-Based

model/metric	Recall@10	Precision@10	NDCG@10	F1	Similarity(User)	Diversity(Item)	Trade-Off
LightGCN	0.4959	0.3034	0.4930	0.3766	0.4832	0.5837	0.4746

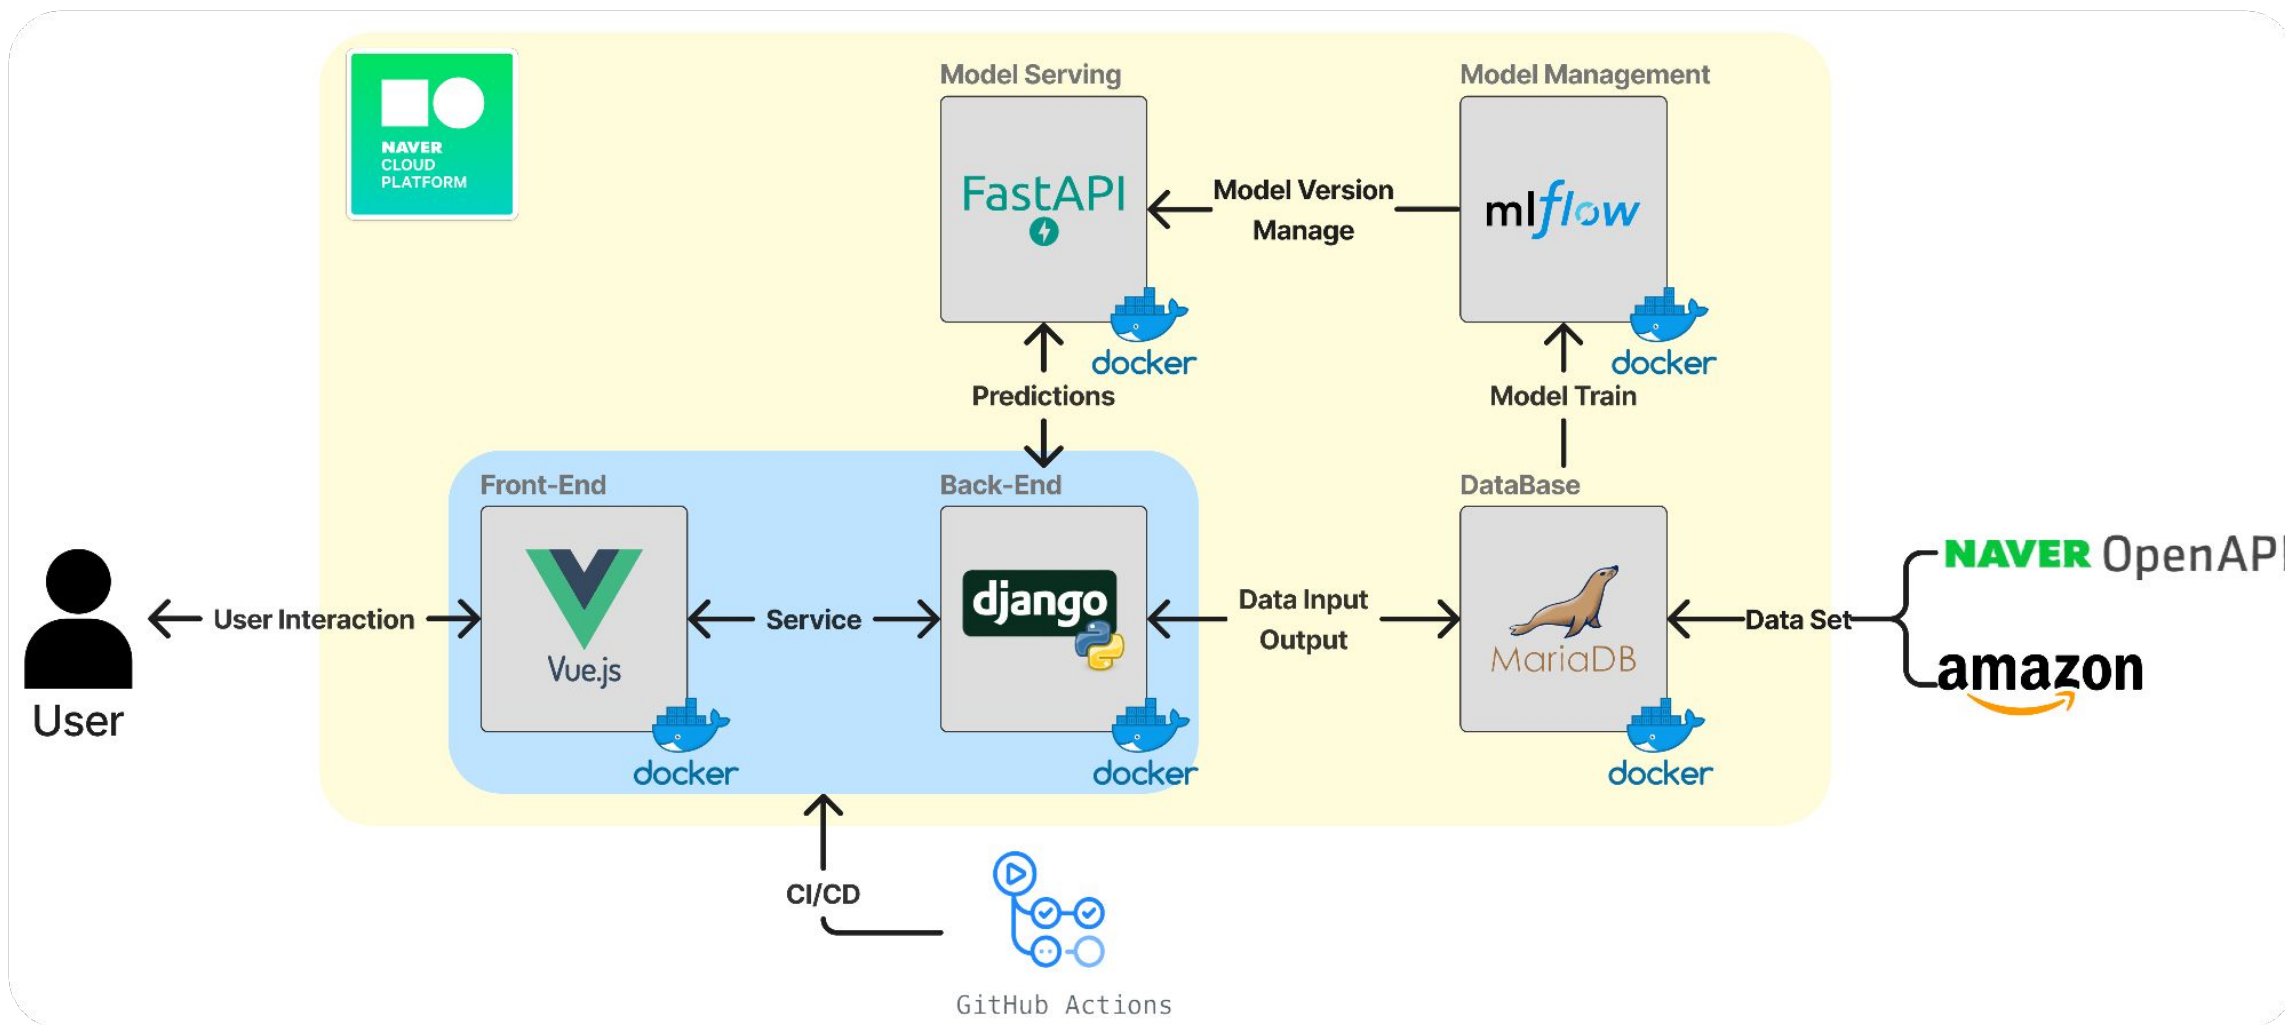
3. Product serving

3.1 서비스 아키텍처

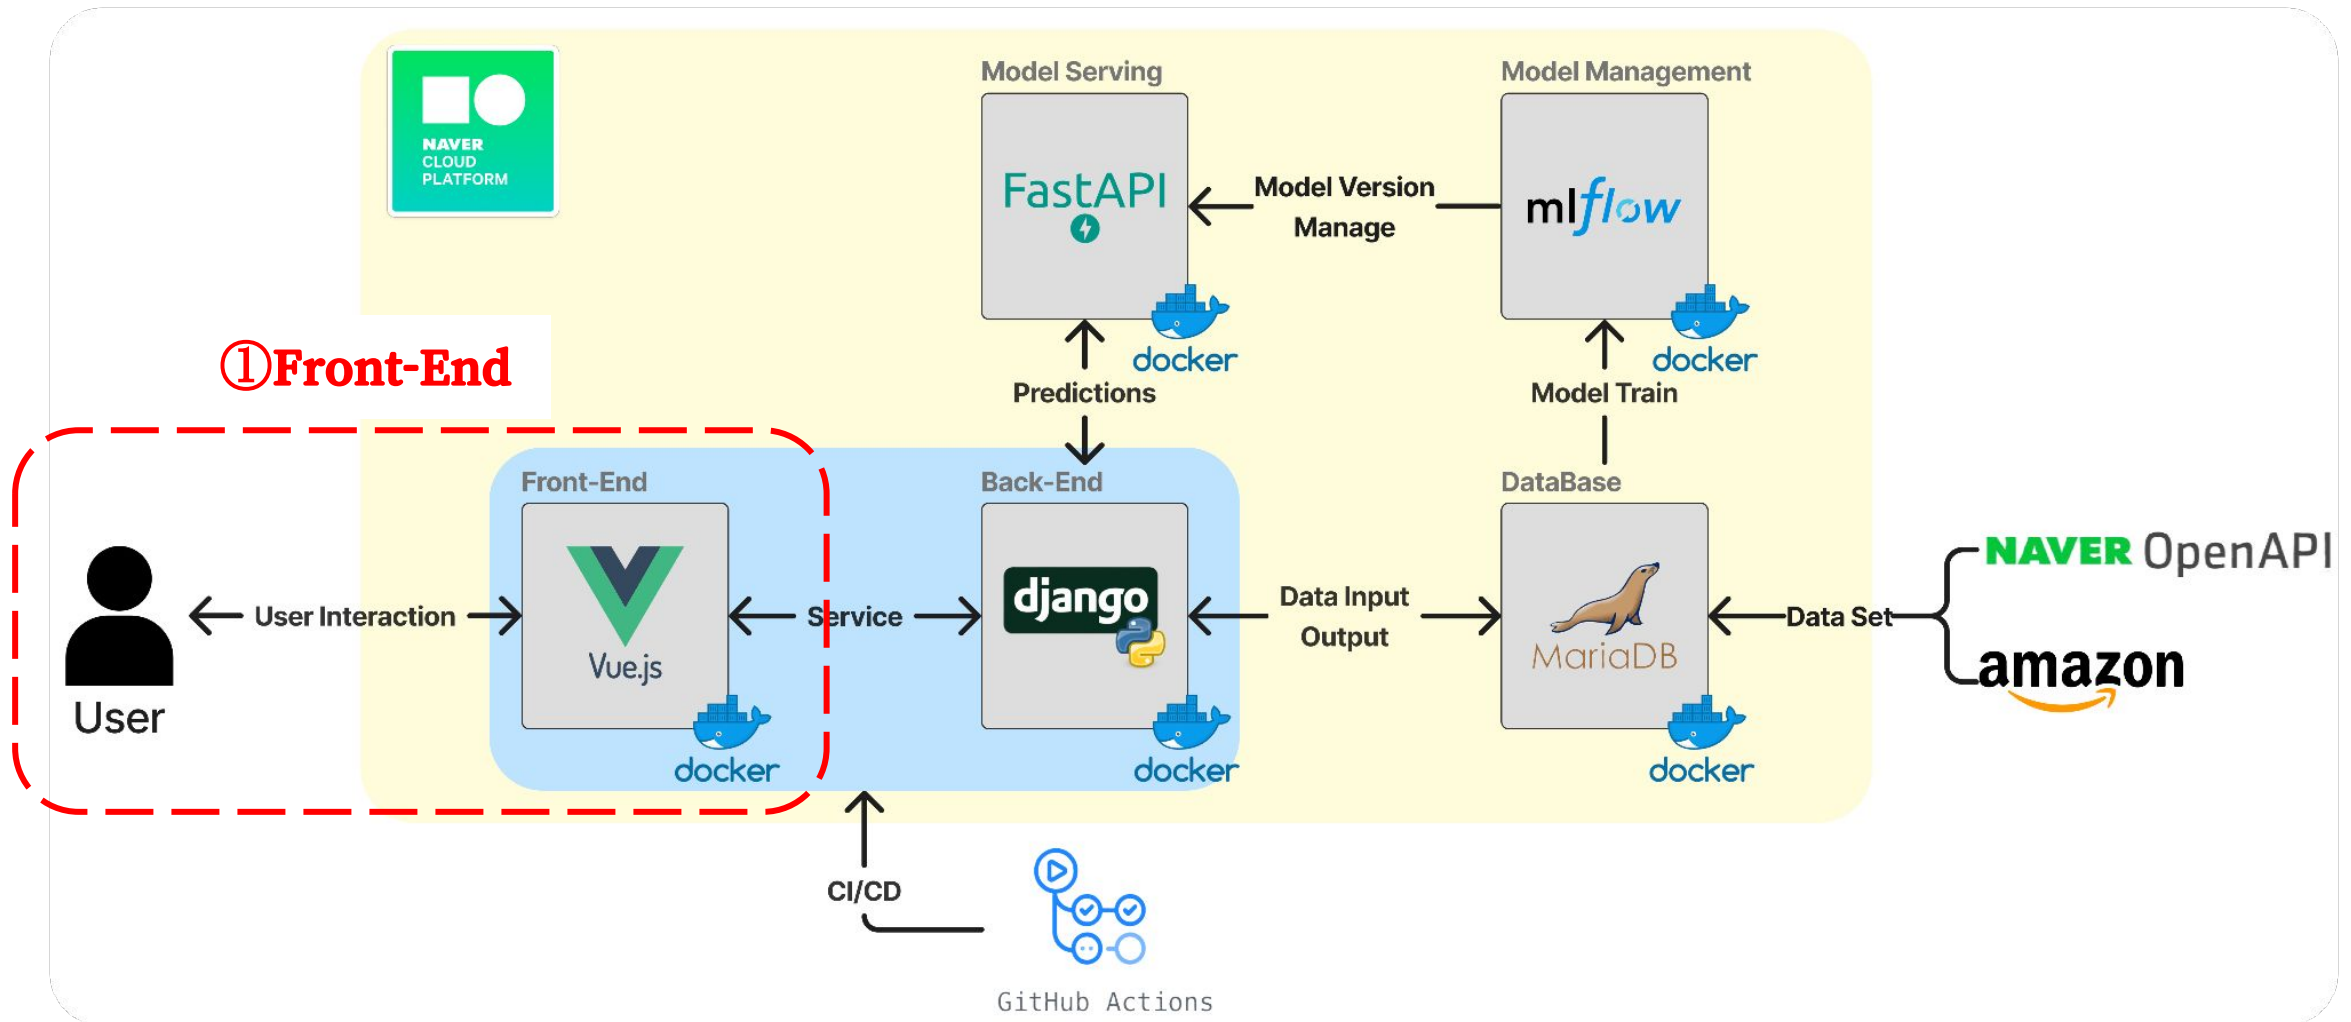
3.2 구현

3.3 데모

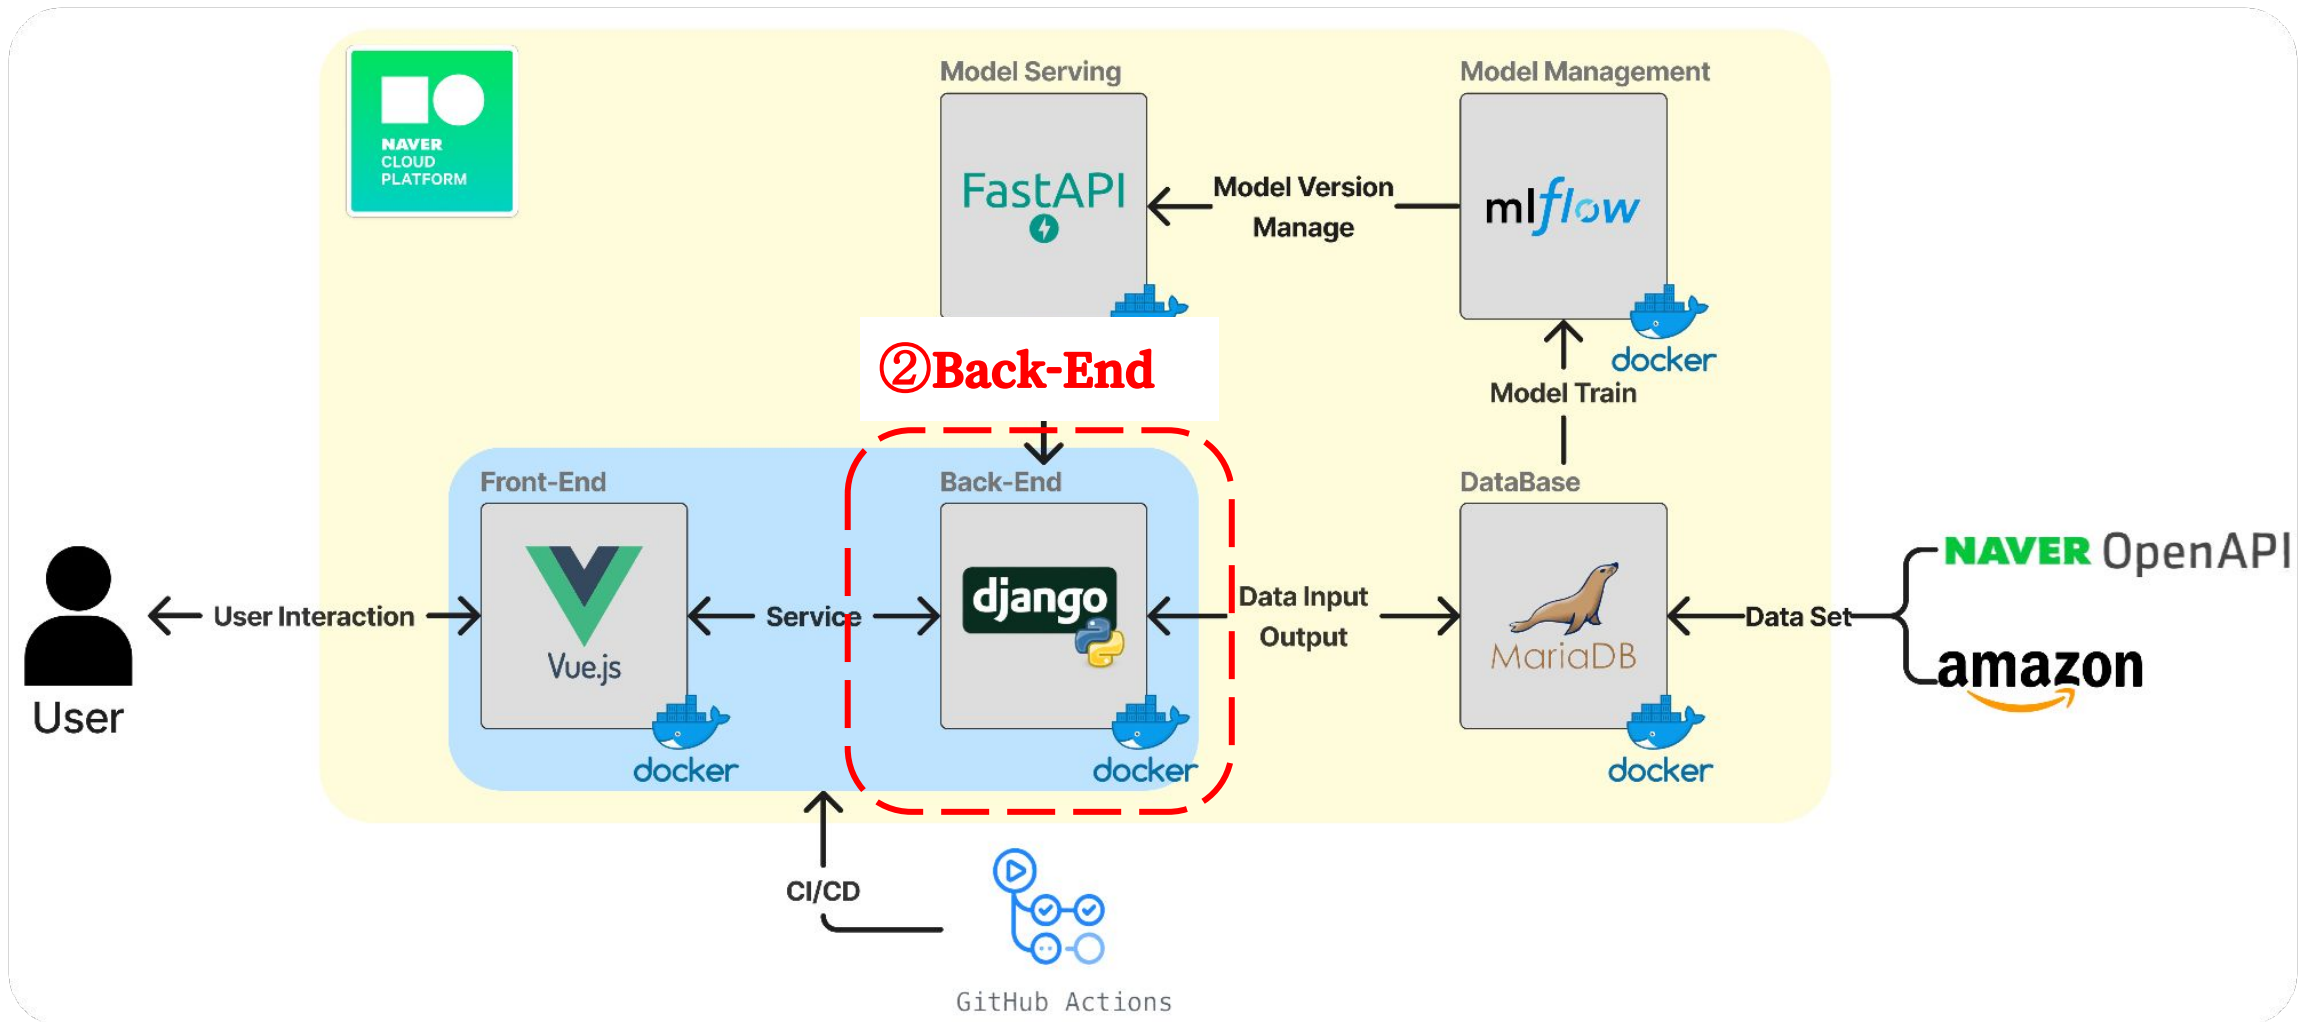
3.1 서비스 아키텍처



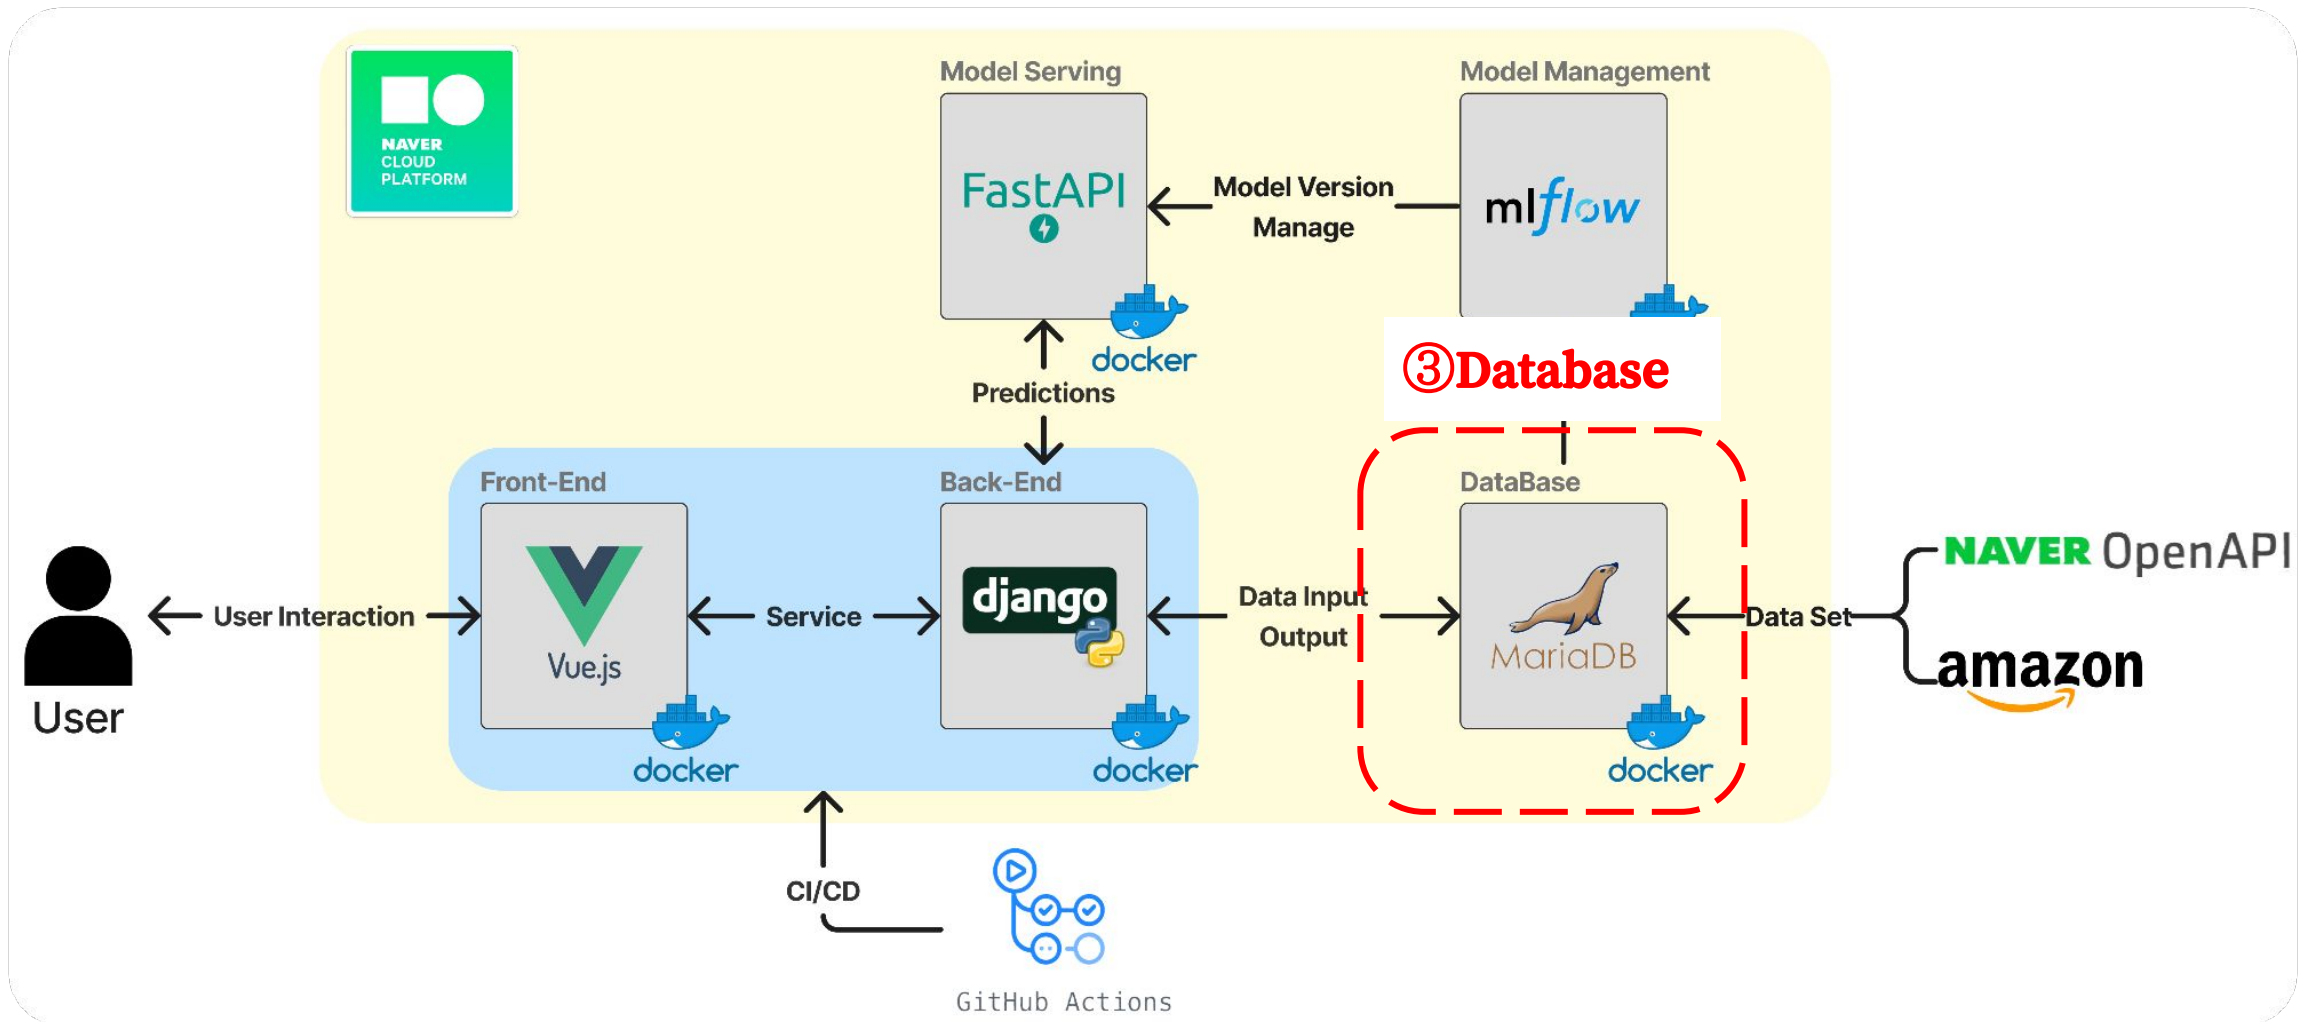
3.1 서비스 아키텍처



3.1 서비스 아키텍처

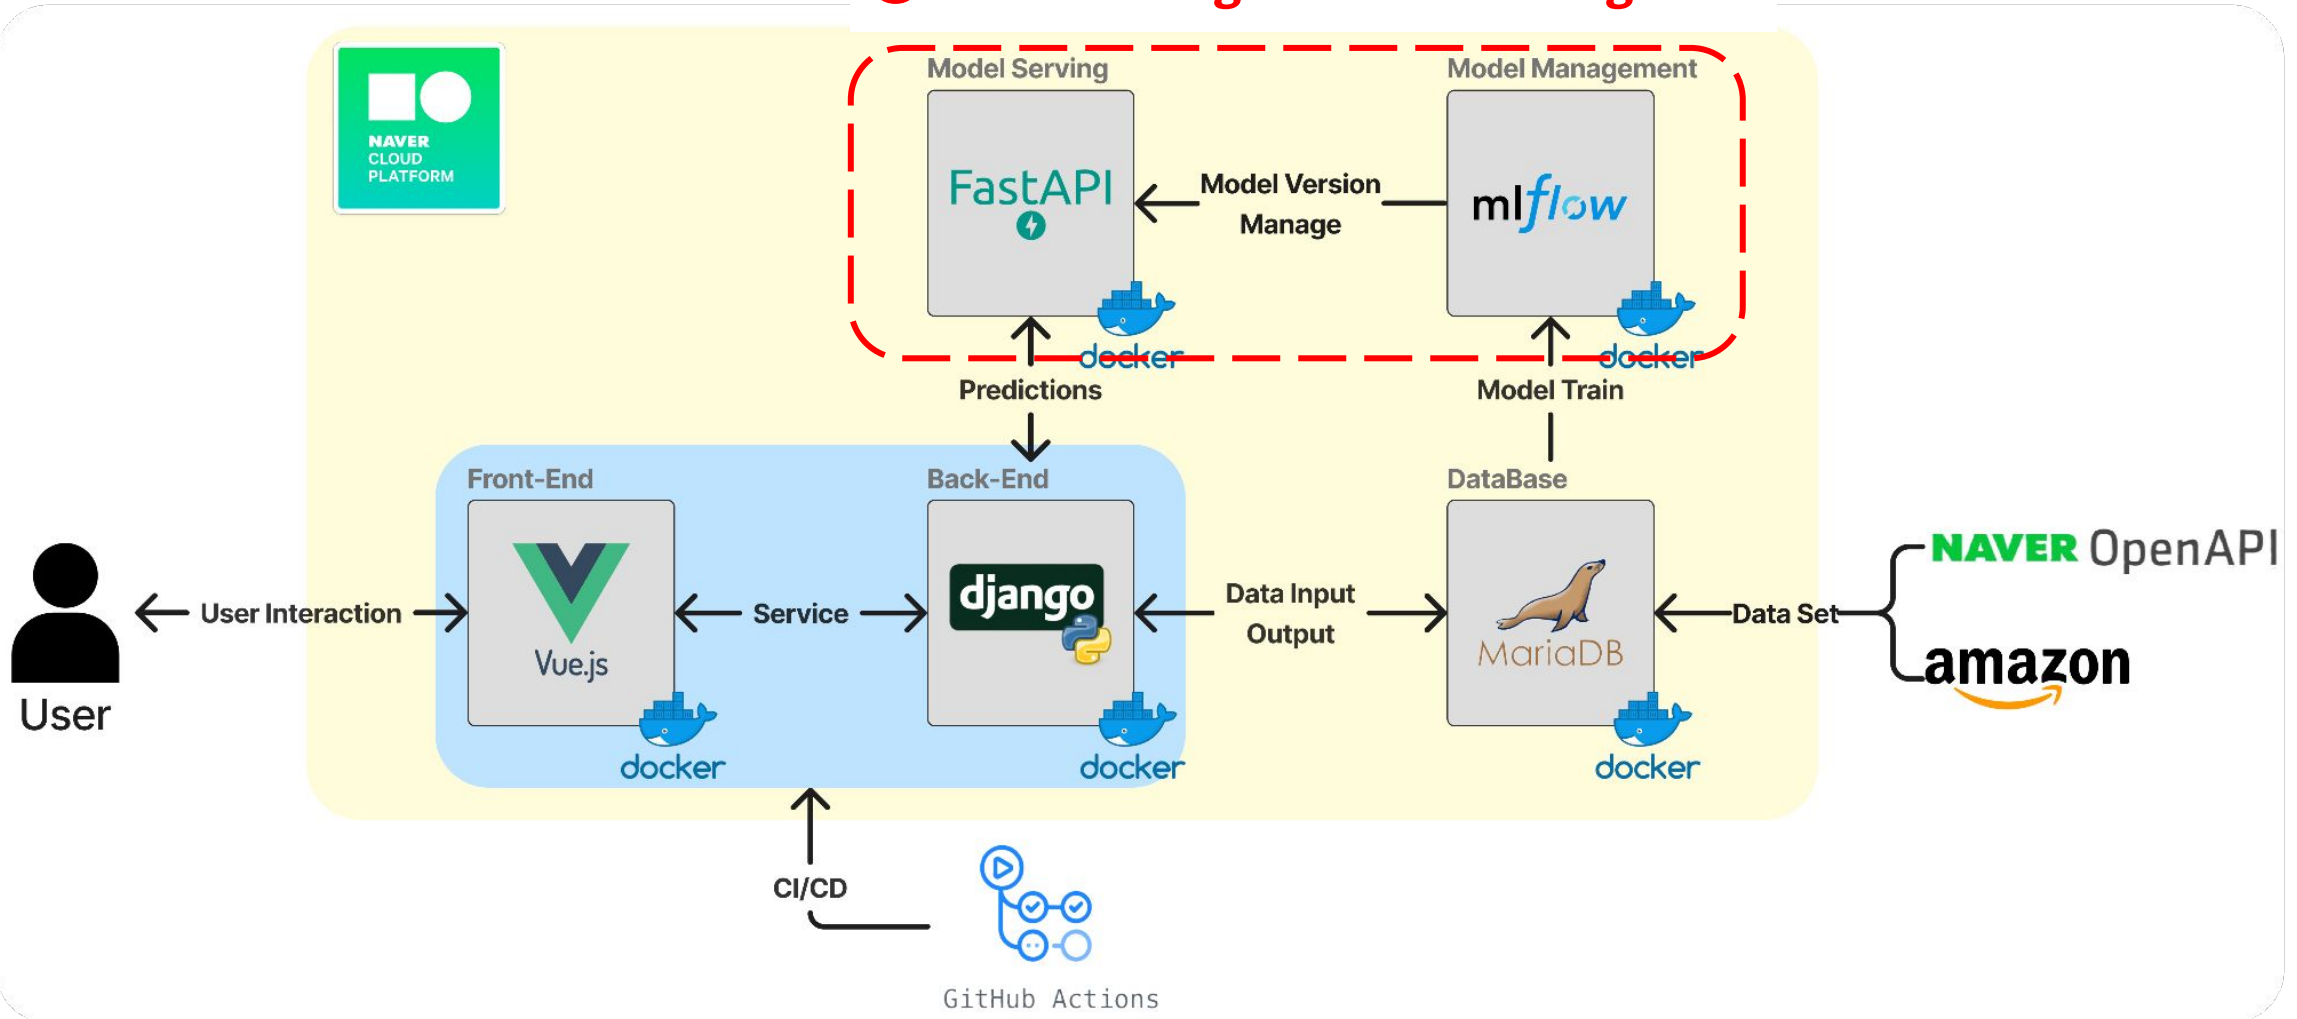


3.1 서비스 아키텍처

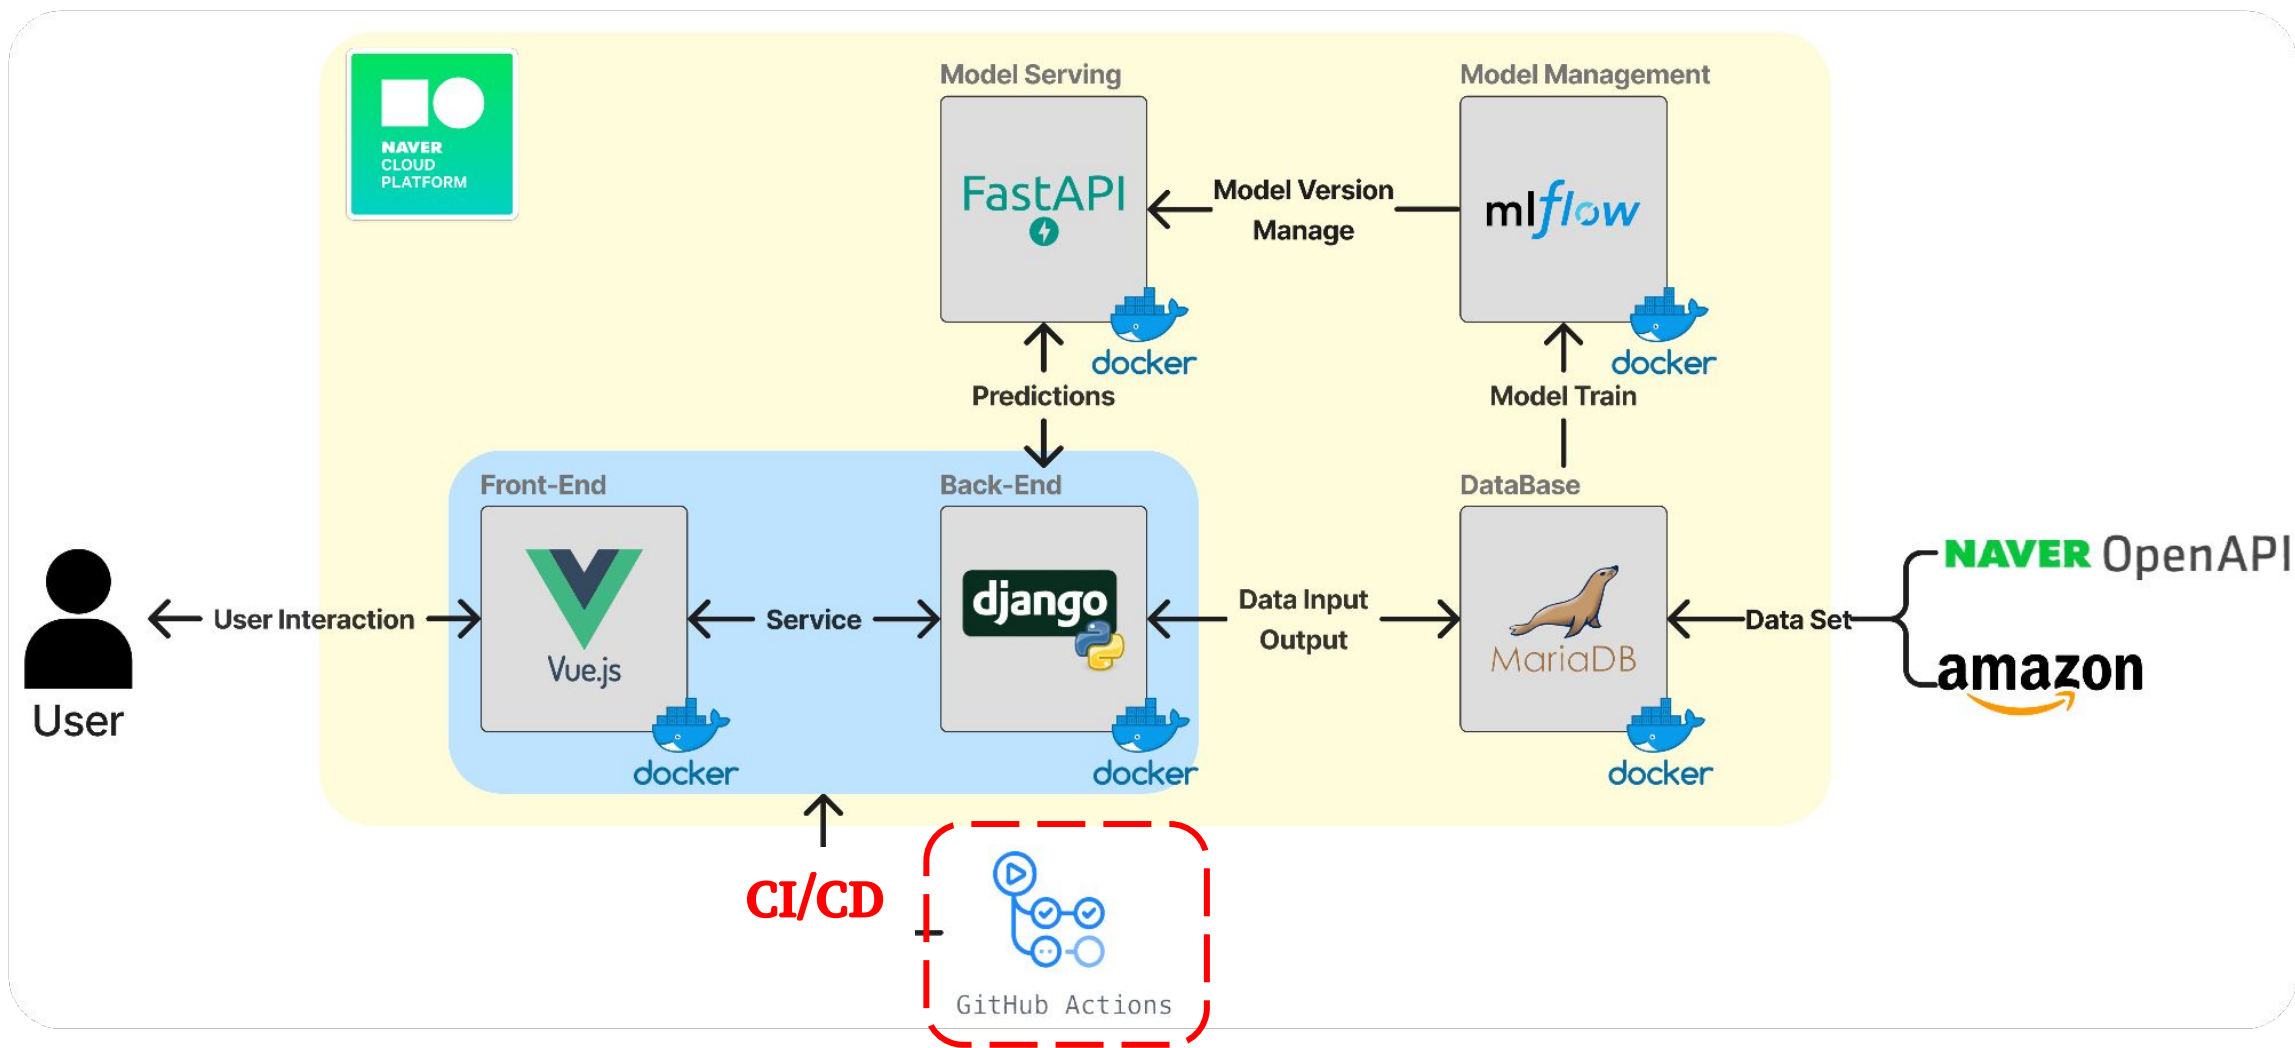


3.1 서비스 아키텍처

④ Model Management & Serving



3.1 서비스 아키텍처




4. result/ conclusion

4.1 시연 영상

4.2 기대효과 및 확장성

4.3 한계점 및 개선점

4.1 시연 영상



4.2 기대효과 및 확장성

기대효과 1 : 유저에게 맞는 **개인화된 서비스** 제공

- 사용자의 이전 구매 이력이나 상호작용을 분석하여 개인화된 선물 추천을 제공
- 선택의 시간을 줄여 보다 의미 있는 생활에 더 많은 시간을 사용할 수 있는 편의성을 제공하여 만족도 증가
- 로그를 기록하여 추후 추천에 있어 중복 방지 및 유저의 기념일을 지속적으로 리마인드하여 유저의 재이용을 증가 예상

기대효과 2 : 상품을 바탕으로 추천

- **cold start** 상황을 **해결**할 수 있음
- 추후 유저의 데이터가 누적됨에 따라 CF모델을 발전시켜 개인화 추천이 시연과 같이 가능할 것이라 예상

기대효과 3 : 비즈니스적 확장

- 개인화된 서비스를 바탕으로 **유저의 상황에 맞는 혜택을 제공**하여 효율적인 매출을 얻을 수 있을 것이라 예상

기대효과 4 : 확장성

- 알고리즘에 따라 구현한 모델에 대한 **재학습 및 구조적 발전 가능성**이 높음
- 추후 유저의 데이터의 누적 및 알고리즘의 개선을 통해 더 만족스러운 추천 결과를 얻을 수 있을 것이라 예상

4.3 개선점

1. 예비 테스트를 위한 데이터 connection 구현

- 프로젝트의 구조 상 사용자의 정보를 얻지 못해 전체 구조가 매끄럽게 이어지지 못함
- 추후 **유저의 데이터가 누적**됨에 따라 원활한 2stage 모델의 기획

2. 상품 이미지, 리뷰 등을 이용한 multimodal 구조의 활용

- 쇼핑 데이터는 상품의 이미지와 리뷰, 쇼핑 아이템에 대한 설명을 활용하는 경우가 많지만 이와 관련된 데이터를 수집하고 전처리 하는데 제약을 겪음
- 멀티모달 데이터의 처리의 결과로 생성된 **추가적인 feature**를 바탕으로 한 더 정확하고 다양한 추천시스템을 만들 수 있을 것이라 기대

3. A/B 테스트 진행을 통한 online metric 확인

- 여러 모델을 만들어도 이를 통합하는 것이 더 나은 추천을 하는지 확인할 수 없음
- 실제 서비스를 통해 CTR, Coverage와 같은 **online metric**를 **적극 활용**하여 유저의 만족도를 추가적으로 확인할 수 있을 것으로 기대

4. AirFlow와 같은 실시간 서빙 툴 활용 방안

- 프로젝트 규모와 효용성 측면을 고려했을 때 **AirFlow, MLFlow**와 같은 실시간 서빙을 위한 툴을 사용해야할 필요성을 느끼지 못함
- 데이터 수집 및 모델 학습을 주기적으로 진행하는 플랜을 세운다면 추후 이를 적극적으로 활용할 수 있을 것이라고 생각

5. Appendix

5.1 팀원 구성

5.2 협업 전략

5.3 프로젝트 타임라인

5.4 Reference

5.1 팀원 및 역할

팀원	역할
김세훈	<ul style="list-style-type: none">PM : S/W 아키텍처 설계, 프로젝트 일정관리백엔드 : Django Framework를 활용하여 프론트엔드, DB, Model 간 인터페이스 서버 구축모델 서빙 : 개발된 모델을 mlflow의 REST API 통신 인터페이스 구축
김시윤	<ul style="list-style-type: none">선행 연구 및 분석EDA 및 데이터 필터링 & 전처리모델링 : LightGBM 개발 및 실험, User Based CF 기반 LightGCN 모델 개발 및 실험, Item Based CF 기반 모델 수정 및 실험
문찬우	<ul style="list-style-type: none">Docker를 활용하여 NCP 서버에 MariaDB 구축아마존 데이터 EDA 및 CF 기반 EASE 모델 실험네이버 데이터 와 아마존 데이터의 product_id 간의 유사도 확인을 위한 sentence transformer 구현 및 실험
배건우	<ul style="list-style-type: none">DB 테이블 설계 및 정규화, ERD 작성LGBM기반 모델 코드 리팩토링 진행
이승준	<ul style="list-style-type: none">프론트엔드 : composition API 방식으로 스크립트 코드 작성, pinia를 이용한 데이터 관리, vue3 라이프사이클 혹은 활용한 데이터 렌더링UI/UX 개선 : tailwind 적용, 클래스 바인딩을 활용한 조건에 따른 디자인 적용모델링 및 데이터 처리 : 아마존 데이터 EDA 및 전처리, CF 기반 EASE 모델 개발

5.2 협업 전략 Notion

Project View






2024년 3월

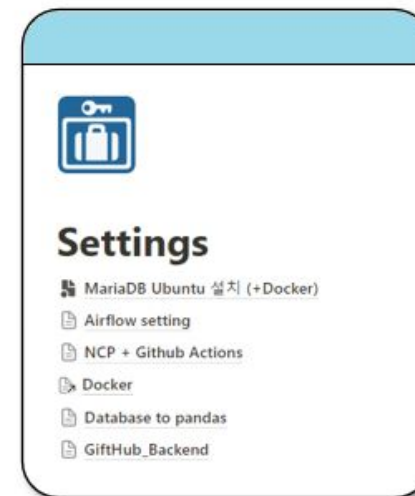
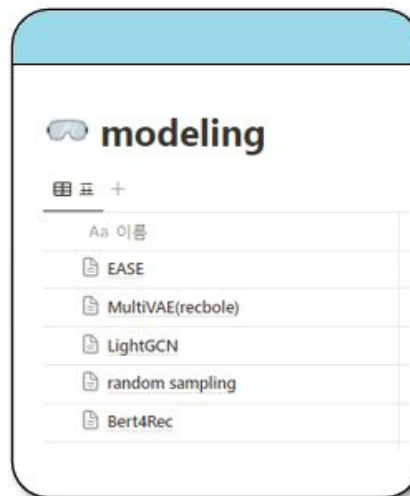
< 오늘 >

일	월	화	수	목	금	토
25	26	27	28	29	3월 1일	2
	강의 수강 및 서버 세팅					각 파트 별 기초 강의 수강
3	4	5	6	7	8	9
각 파트 별 기초 강의 수강	각자 기능 구현					프로토타입 기능 구현
	Database 연결 테스트		Front & Back 기능 구현 (1)			Front & Back 기능 구현 (2)
	프론트 & 백엔드 API 테스트				데이터 필터링 관련	시윤 모델링 관련 해야 0:00 1
10	11	12	13	14	15	16
프로토타입 기능 구현						
Front & Back 기능 구현 (2)		1차 프로토타입 시연 (연결 1	프로젝트 회의	멘토링 피드백 정리	아마존 데이터 모델 학습	
시윤 모델링 관련 해야할 일 1				Stage 2 제작		
17	18	19	20	21	22	23
프로토타입 기능 구현	프로토타입 통합 테스트		1차 제출		1차 제출에 대한 멘토 피드백	
프로토타입 통합	멘토링	시연 영상 제작				
24	25	26	27	28	29	30
	멘토링		최종 프로젝트 제출			
31	4월 1일	2	3	4	5	6
	랩업 레포트 제출	네트워킹데이 & 수료식				

5.2 협업 전략 Notion

Level3 - Final Project

 Kanban	최종 프로젝트 칸반보드
 Final Project docs	최종 프로젝트의 기술이나 프로젝트 내용에 대한 명세서 모음
 Frontend	프론트엔드 관련 기술/용어 정리
 modeling	모델 실험 결과 정리 페이지
 Settings	이것저것 세팅하는 법





5.2 협업 전략 Notion

Kanban

 To Do List  캘린더  문서  Roadmap  ALL

To Do 2

 시윤 모델링 관련 해야할 일

 시윤 김

 1

 Front & Back 기능 구현 (2)


김 김세훈  이승준

+ 새로 만들기


Done 3

 Front & Back 기능 구현 (1)


 이승준  김 김세훈

 프론트 & 백엔드 API 테스트

김 김세훈  이승준

 1차 프로토타입 시연 (연결 테스트)

김 김세훈  시윤 김


 문찬우(학부생-AI빅데이터융합경영학과)

 건우 배  이승준


 1

+ 새로 만들기

Back Log 1

 프로젝트 회의


김 김세훈  시윤 김

 문찬우(학부생-AI빅데이터융합경영학과)


 건우 배  이승준

+ 새로 만들기

In Progress 1

 아마존 데이터 모델 학습

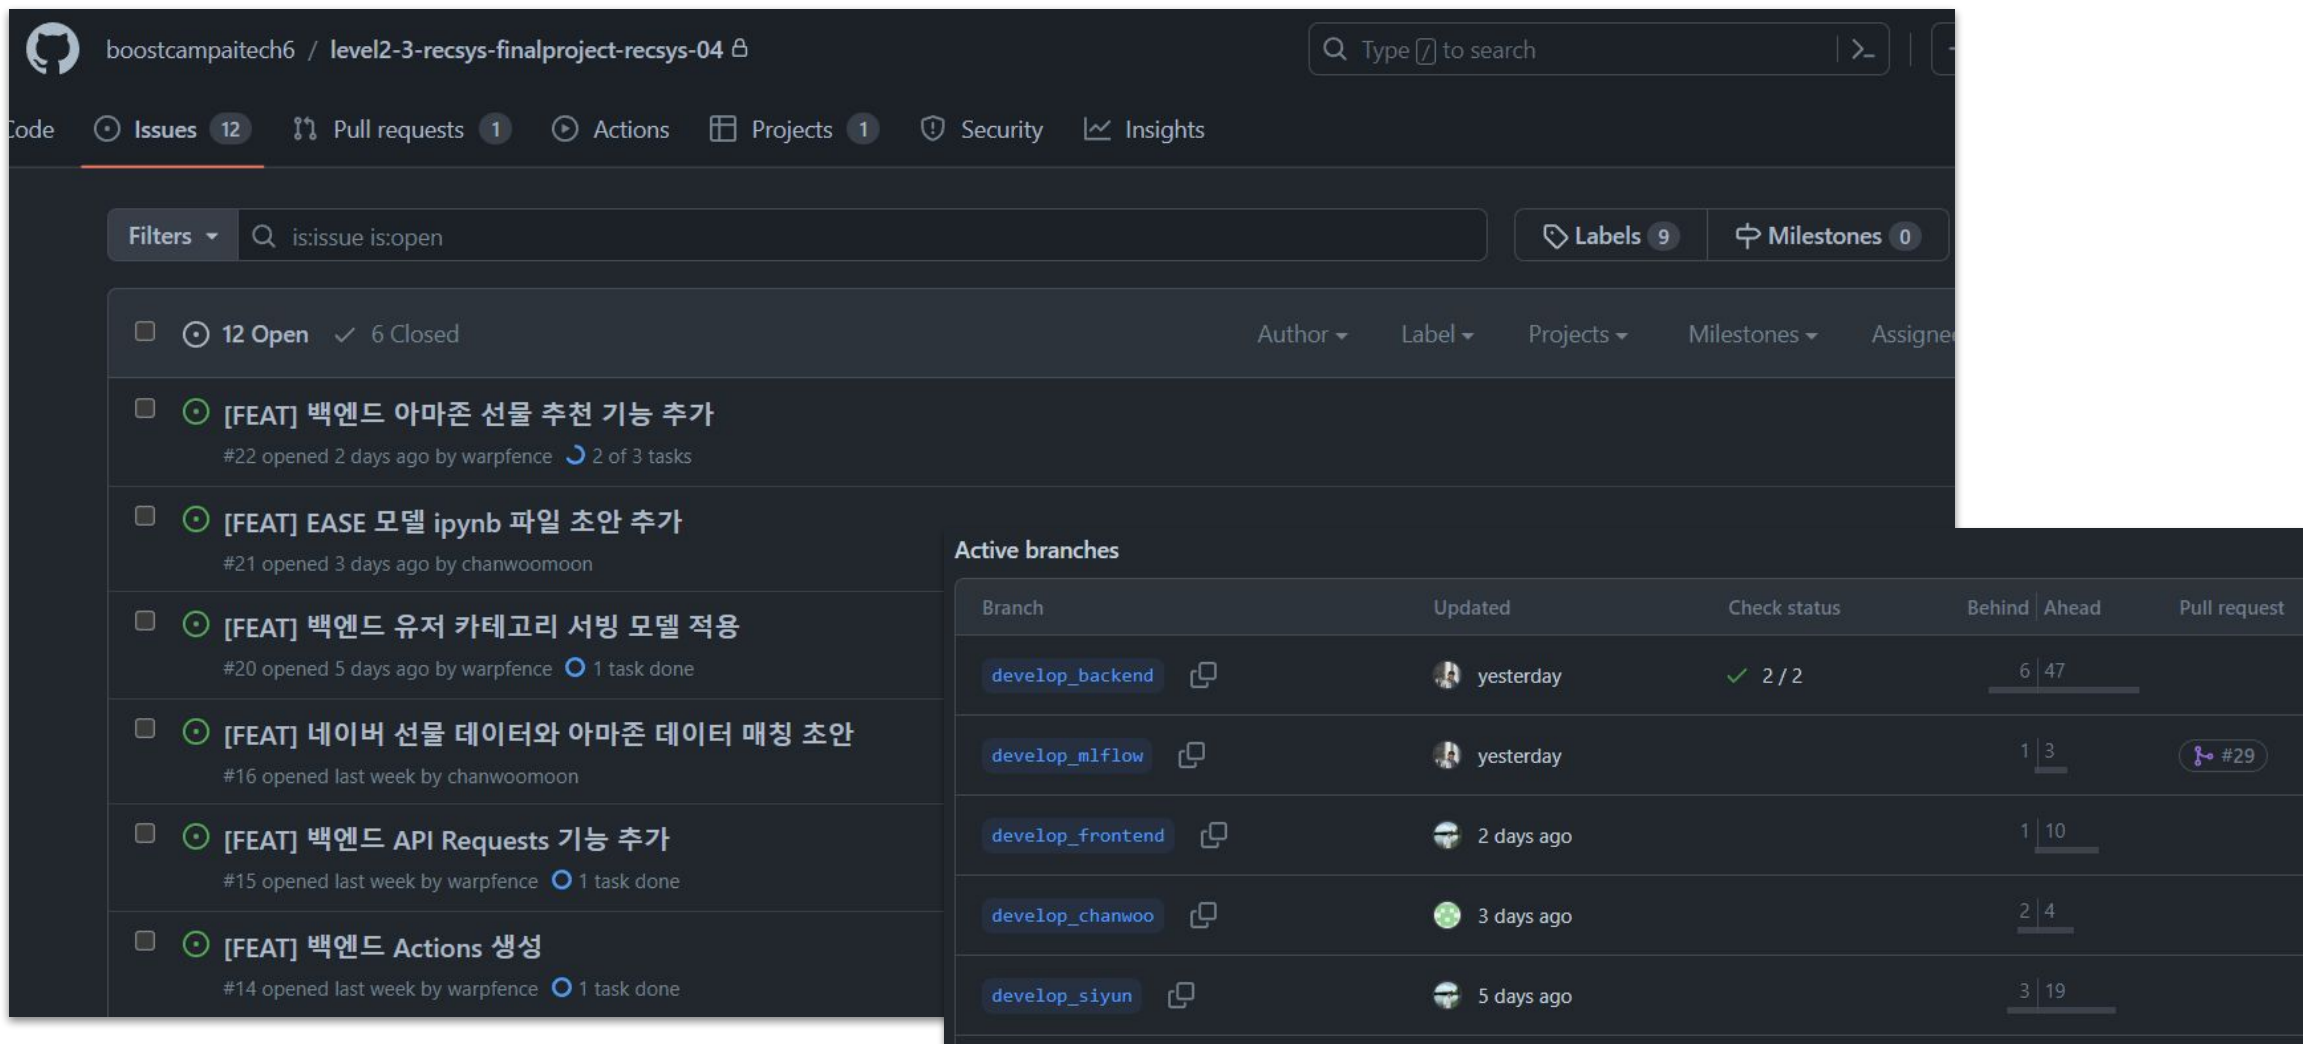
김 김세훈  시윤 김

 문찬우(학부생-AI빅데이터융합경영학과)

 건우 배  이승준

+ 새로 만들기

5.2 협업 전략 GitHub



boostcampaitech6 / level2-3-recsys-finalproject-recsys-04

Code Issues 12 Pull requests 1 Actions Projects 1 Security Insights

Filters is:issue is:open Labels 9 Milestones 0

12 Open 6 Closed

Author Label Projects Milestones Assignee

- [FEAT] 백엔드 아마존 선물 추천 기능 추가
#22 opened 2 days ago by warpence 2 of 3 tasks
- [FEAT] EASE 모델 ipynb 파일 초안 추가
#21 opened 3 days ago by chanwoomoon
- [FEAT] 백엔드 유저 카테고리 서빙 모델 적용
#20 opened 5 days ago by warpence 1 task done
- [FEAT] 네이버 선물 데이터와 아마존 데이터 매칭 초안
#16 opened last week by chanwoomoon
- [FEAT] 백엔드 API Requests 기능 추가
#15 opened last week by warpence 1 task done
- [FEAT] 백엔드 Actions 생성
#14 opened last week by warpence 1 task done

Active branches

Branch	Updated	Check status	Behind	Ahead	Pull request
develop_backend	yesterday	✓ 2 / 2	6	47	
develop_mlflow	yesterday		1	3	#29
develop_frontend	2 days ago		1	10	
develop_chanwoo	3 days ago		2	4	
develop_siyun	5 days ago		3	19	

5.3 프로젝트 타임라인

ID	작업 이름	시작	완료	2월														3월																								
				16	17	18	19	20	21	22	23	24	25	26	27	28	29	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25
1	데이터 수집 및 전처리 (네이버 데이터 크롤링)	2024-02-16	2024-02-18																																							
2	아키텍처 구체화 및 플랫폼 결정	2024-02-19	2024-02-23																																							
3	데이터 베이스 구축	2024-02-27	2024-03-01																																							
4	강의 수강 및 서버 세팅	2024-03-04	2024-03-05															데이터 베이스 연결 테스트 및 프론트 & 백엔드 API 테스트																								
5	프론트 & 백엔드 기능 구현 및 모델링	2024-03-06	2024-03-24															1차 프로토 타입 시연1차 제출최종 제출																								
6	> Stage 1 제작 (Candidate 부분 제작)	2024-03-06	2024-03-11																																							
7	> Stage 2 제작 (Ranking 부분 제작)	2024-03-14	2024-03-18																																							
8	> 아마존 데이터 모델 학습	2024-03-15	2024-03-18																																							
9	1차 피드백 내용 수정	2024-03-22	2024-03-24																																							

5.4 Reference

Covington, P., Adams, J., & Sargin, E. (2016, September). Deep neural networks for youtube recommendations. In *Proceedings of the 10th ACM conference on recommender systems* (pp. 191–198).

He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., & Wang, M. (2020, July). Lightgcn: Simplifying and powering graph convolution network for recommendation. In *Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval* (pp. 639–648).

Raza, S., Bashir, S. R., & Naseem, U. (2022, October). Accuracy meets Diversity in a News Recommender System. In *Proceedings of the 29th International Conference on Computational Linguistics* (pp. 3778–3787).

Steck, H. (2019, May). Embarrassingly shallow autoencoders for sparse data. In *The World Wide Web Conference* (pp. 3251–3257).

Sun, F., Liu, J., Wu, J., Pei, C., Lin, X., Ou, W., & Jiang, P. (2019, November). BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformer. In *Proceedings of the 28th ACM international conference on information and knowledge management* (pp. 1441–1450).

Yin, Q., Fang, H., Sun, Z., & Ong, Y. S. (2023). Understanding Diversity in Session-Based Recommendation. *ACM Transactions on Information Systems*, 42(1), 1–34.

<https://github.com/microsoft/LightGBM>

<https://sumniya.tistory.com/26>

<https://walwalgabu.tistory.com/entry/4-NDCG-Normalized-Discounted-Cumulative-Gain%ED%8F%89%EA%B0%80%EC%A7%80%ED%91%9C>

<https://blog.nerdfactory.ai/2021/09/23/recommend-system-classification-metric-1.html>

<https://wikidocs.net/24603>

<https://glanceyes.com/entry/Embarrassingly-Shallow-Autoencoders-for-Sparse-Data-%EB%AA%A8%EB%8D%B8%EC%9D%B4-%ED%9D%AC%EC%86%8C-%EB%8D%B0%EC%9D%B4%ED%84%B0%EC%97%90-%EA%B0%95%ED%95%9C-%EC%9D%B4%EC%9C%A0>

End of Document

Thank You.